

Universidad Nacional
de Educación a Distancia

Escuela Técnica Superior de Ingeniería Informática

Estudio del impacto del aumento de datos con GANs sobre imágenes térmicas en un modelo predictivo del cáncer de mama

Autor: Rafael Román Aguilar

Director/a: Mariano Rincón Zamorano
Co-director/a: José Manuel Cuadra Troncoso

Trabajo de Fin de Máster

Máster Universitario
en Ingeniería y Ciencia de Datos

Junio de 2025

Agradecimientos

Quisiera agradecer a mi familia por apoyarme siempre en todo, a mis amigos Luis y Raúl porque la convivencia con ellos ha hecho que la realización de este trabajo sea mucho más amena, a José Manuel Cuadra Troncoso y Mariano Rincón Zamorano por haberme guiado durante todo este proceso; y finalmente, a la empresa que me despidió e intentó engañarme, porque si no hubiera sido por eso nunca hubiera emprendido el viaje de estudiar este máster y adentrarme en el mundo de la Inteligencia Artificial.

Resumen

El carcinoma de mama es una de las causas principales de muerte entre las mujeres, lo que hace fundamental su detección temprana. Diversos estudios han destacado el uso de imágenes térmicas como una herramienta prometedora para la detección temprana. En un trabajo de fin de máster previo, se desarrollaron modelos de aprendizaje profundo con mecanismos de atención para detectar el cáncer de mama a partir de imágenes térmicas. Este arrojó buenos resultados pero se llevó a cabo con un conjunto de datos de 260 imágenes, lo que dificulta la generalización de los resultados. Este proyecto propone utilizar aumento de datos mediante Redes Generativas Adversativas (GANs por sus siglas en inglés) para generar imágenes nuevas al conjunto de datos y evaluar el impacto en los resultados obtenidos con el mejor modelo del anterior trabajo, que utiliza mecanismos de atención dura.

Se selecciona *StyleGAN* como modelo generativo adversativo por la robustez durante el entrenamiento y la calidad de las imágenes generadas y se utiliza *KID y FID Score* como métricas de evaluación, ya que permiten comparar el rendimiento de los modelos y cuantificar la calidad de las imágenes generadas. Gracias a estas métricas, se define un procedimiento con el que poder seleccionar las mejores imágenes generadas para el aumento de datos y se realiza una afinación de hiperparámetros a los modelos que generan tanto las muestras sanas como las enfermas. Se diseña un procedimiento para evaluar el modelo de predicción que consiste en una validación cruzada y se repite 10 veces para evitar sesgos en los resultados. Se llevan a cabo experimentos incorporando distintas cantidades de imágenes generadas: 0 (datos reales más aquellos con transformaciones de aumento de datos), 768 (25 % del conjunto de datos), 1536 (50 %), 2304 (75 %) y 3072 (100 %). Este número de imágenes generadas se integran al conjunto de datos para analizar el impacto en el rendimiento del modelo predictivo.

Para evaluar el modelo de predicción se emplean las mismas métricas que en el trabajo anterior: exactitud, especificidad, precisión, exhaustividad, puntuación F1, área bajo la curva ROC (AUC) y matriz de confusión. Los experimentos donde se incluyen imágenes generadas muestran mejores resultados que aquel donde se utiliza únicamente el conjunto de datos base. Se destaca el experimento donde se introduce un 50 % de imágenes generadas por obtener mejor valor AUC, menor tiempo de ejecución que otros experimentos y conseguir una exhaustividad media de 0.845 con una varianza/desviación de 0.008/0.09, con respecto al experimento del conjunto base que obtuvo una media, varianza y desviación típica de 0.838 y 0.006/0.08 respectivamente. Esos resultados sugieren el impacto positivo del aumento de datos mediante imágenes generadas en conjuntos de datos pequeños.

Palabras clave: Cáncer de mama, imágenes térmicas, Aprendizaje profundo, mecanismos de atención, Redes generativas Adversativas, aumento de datos, afinación de hiperparámetros, validación cruzada.

Abstract

Breast cancer is one of the leading causes of death among women, making early detection essential. Several studies have highlighted the use of thermal images as a promising tool for early detection. In a previous master's thesis, deep learning models with attention mechanisms were developed to detect breast cancer from thermal images. This yielded good results but was conducted on a dataset of 260 images, making generalization difficult. This project proposes using data augmentation using Generative Adversarial Networks (GANs) to generate new images for the dataset and evaluate the impact on the results obtained with the best model from the previous work, which uses hard attention mechanisms.

StyleGAN is selected as the generative adversarial model due to its robustness during training and the quality of the generated images. KID and FID Score are used as evaluation metrics, as they allow comparing model performance and quantifying the quality of the generated images. Using these metrics, a procedure is defined to select the best generated images for data augmentation, and hyperparameter tuning is performed on the models that generate both healthy and sick samples. A procedure is designed to evaluate the prediction model, consisting of cross-validation and repeated 10 times to avoid bias in the results. Experiments are carried out incorporating different numbers of generated images: 0 (real data plus those with data augmentation transformations), 768 (25% of the dataset), 1536 (50%), 2304 (75%), and 3072 (100%). This number of generated images is integrated into the dataset to analyze the impact on the performance of the predictive model.

The same metrics as in the previous work are used to evaluate the prediction model: accuracy, specificity, precision, recall, F1 score, area under the ROC curve (AUC) and confusion matrix. Experiments that include generated images show better results than the one that uses only the base dataset. The experiment that introduces 50% generated images stands out for obtaining a better AUC value, shorter runtime than other experiments, and achieving an average recall of 0.845 with a variance/deviation of 0.008/0.09, with respect to the base set experiment, which obtained mean, variance, and standard deviation of 0.838 and 0.006/0.08, respectively. These results suggest the positive impact of data augmentation using generated images on small datasets.

Keywords: Breast cancer, thermal imaging, deep learning, attention mechanisms, generative adversarial networks, data augmentation, hyperparameter tuning, cross-validation.

Nomenclatura

AdaIN Normalización de instancia adaptativa, page 12

AUC Área bajo la curva, page 20

cGANs Redes Generativas Adversarias condicionales, page 12

CNN Redes Neuronales Convolucionales, page 8

DAGAN Redes Generativas Adversarias del Aumento de datos, page 21

DCGAN Redes Generativas Adversarias convolucionales profundas, page 9

FC Redes completamente conectadas, page 12

FID *Fretchet Inception Distance*, page 20

FN Falsos Negativos, page 19

FP Falsos Positivos, page 19

GANs Redes Generativas Adversarias, page 2

GRANs Redes de atención recurrente gráfica, page 9

IS *Inception Score*, page 20

KID *Kernel Inception Distance*, page 20

LR Ratio de aprendizaje, page 38

MMD Media de la discrepancia máxima, page 20

ROC Característica Operativa del Receptor, page 20

sGAN Redes Generativas Adversarias semisupervisadas, page 28

TN Verdaderos Negativos, page 19

TP Verdaderos Positivos, page 19

VAE Autocodificador Variacional, page 10

WGAN Redes Generativas Adversarias de Wasserstein, page 15

Índice general

Nomenclatura IX

1. Introducción **1**
1.1. Motivación 1
1.2. Propuesta y objetivos 3
1.3. Metodología 4
1.4. Estructura del documento 5

2. Estado del Arte **7**
2.1. Fundamentos 7
2.1.1. Aprendizaje profundo, mecanismos de atención y Grad-CAM 7
2.1.2. Redes Generativas Adversarias (GANs) 8
2.1.3. StyleGAN 12
2.1.4. Aumento de datos 16
2.1.5. Afinación de hiperparámetros 17
2.1.6. Métricas de evaluación 18
2.2. Trabajos relacionados 21
2.2.1. Aumento de datos con GANs para modelo de predicción 21
2.2.2. Entrenamiento de GANs con datos limitados 22

3. Métodos **27**
3.1. Conjunto de datos 27
3.2. Modelo GAN seleccionado 28
3.3. Entrenamiento del GAN 30
3.4. Métricas de evaluación 34
3.5. Aumento de datos 35
3.6. Aumento de datos sin filtrado de transformaciones 36
3.7. Afinación de hiperparámetros 38
3.8. Validación cruzada 40
3.9. Entrenamiento completo y evaluación 44

4. Resultados **47**
4.1. Resultados de los GANs 47
4.2. Métricas de evaluación del modelo predictivo 50
4.3. Tiempos de ejecución 55
4.4. Grad-CAM 56
4.5. Fallos de convergencia 58
4.6. Discusión 58

5. Conclusiones y trabajos futuros **61**
5.1. Conclusiones 61
5.2. Trabajos futuros 62

Bibliografía y referencias **64**

Índice de figuras

2.1. Método Grad-CAM sobre paciente 373. 9
2.2. Proceso de entrenamiento de los GANs. 10
2.3. Colapso de modo en los GANs. 12
2.4. Comparación entre la estructura del GAN tradicional y *StyleGAN*. 13
2.5. Ejemplos de variación estocástica. 14
2.6. Ejemplos de técnicas de transferencia de estilo. 15
2.7. Transformaciones utilizadas en el aumento de datos. 17
2.8. Validación cruzada 18
2.9. Muestras generadas por DAGAN con distintas arquitecturas. 22
2.10. Aumento de datos adaptativo en GANs. 24

3.1. Ejemplo del aumento de datos aplicado al conjunto de datos. 28
3.2. Implementación del sGAN utilizado. 29
3.3. Imágenes generadas por los distintos modelos GANs. 31
3.4. Esquema del proceso de redimensionado de las imágenes. 32
3.5. Datos recogidos durante el entrenamiento del StyleGAN. 33
3.6. *KID Score* de las imágenes generadas sin filtrado de transformaciones. 37
3.7. Muestras generadas a través sin filtrado de aumento de datos. 38
3.8. Resultados de la validación cruzada de los modelos del proyecto anterior. . . 41
3.9. Flujo seguido en la validación cruzada 43
3.10. Gráficas generadas en el programa que ejecuta el proceso completo. 45

4.1. Imágenes sanas generadas en la ejecución del experimento del 100 % (3072). . 48
4.2. Imágenes enfermas generadas en la ejecución del experimento del 100 % (3072). 48
4.3. *KID/FID Score* para imágenes sanas y enfermas del experimento seleccionado. 49
4.4. Función de pérdida para sanas y enfermas en dicho experimento. 50
4.5. Matriz de confusión de cada experimento. 53
4.6. Curva ROC y valor AUC de cada experimento. 54
4.7. Tiempo de ejecución de las distintas ejecuciones finales. 56
4.8. Grad-CAM sobre la muestra enferma 192 para cada experimento. 57
4.9. Grad-CAM sobre la muestra enferma 245 para cada experimento. 58
4.10. Fallos de convergencia producidos en los experimentos. 59

Índice de tablas

2.1. Resultados del modelo de predicción con los distintos conjuntos de datos. . . 23

3.1. Resultados obtenidos de las afinaciones de hiperparámetros. 40

4.1. Métricas obtenidas en la evaluación final por el modelo predictivo 52

Capítulo 1

Introducción

Este capítulo servirá como una primera toma de contacto con los temas que se abordarán en este trabajo de fin de máster. Posee una gran importancia ya que permitirá comprender por qué se ha llevado a cabo, los objetivos marcados y los logros de este. Primero, se explicará la idea principal del proyecto y el trasfondo que este posee, a continuación se definirán las metas y objetivos planteados para desarrollarlo, qué procedimientos se han seguido para llevar a cabo estos objetivos y por último, la organización que posee este documento para poder identificar correctamente cada capítulo.

1.1. Motivación

El carcinoma de mama es uno de los tipos de cáncer más comunes en el mundo, estimándose que en 2022 fallecieron 670.000 personas a causa de esta enfermedad. Prácticamente la mitad de todos los casos ocurren en mujeres sin factores de riesgo específicos aparte de la edad y el sexo [OMS, 2024]. Esta enfermedad se origina cuando las células cancerosas comienzan a desarrollarse dentro de los lóbulos que producen leche del seno. En esta etapa (estadio 0), la enfermedad no es letal y se puede detectar con antelación. Sin embargo, cuando estas células se propagan al tejido mamario, se conoce como cáncer invasivo y se producen nódulos o engrosamiento. A partir de aquí, las células cancerosas pueden propagarse a los ganglios linfáticos cercanos u otros órganos, produciendo metástasis, que supone una etapa letal en la mayoría de casos [OMS, 2024].

Debido a la tasa de mortalidad de esta enfermedad, la detección temprana es un tema de vital importancia ya que dependiendo del estadio en el que se identifique la enfermedad, el resultado del tratamiento tiene más probabilidades de ser exitoso. La "Iniciativa de la Comisión Europea para el cribado y diagnóstico del cáncer de mama" sugiere, entre otras técnicas, principalmente realizar detecciones mediante mamografía digital (rayos X) [Holger Schünemann et al., 2020]. Aunque estas tecnologías sean recomendadas por esta institución, hay que tener en cuenta que tienen una serie de costos, efectos e inconvenientes que hacen

que no sean ideales para todas las situaciones y que por tanto se dificulte en muchas ocasiones esas detecciones tempranas que se quieren alcanzar.

Debido a estos inconvenientes, han habido diversos estudios investigando otros métodos con menores costes y mayor eficiencia. Algunos de estos estudios [Manasi B. Rakhunde et al., 2022] indican que la detección del cáncer de mama mediante imágenes térmicas puede llegar a ser una tecnología revolucionaria en este campo. Estas imágenes muestran la temperatura de los objetos de una manera visible, lo que es de gran utilidad en este ámbito debido a que la presencia de tumores y metástasis implica un mayor flujo de sangre; y a su vez, una mayor temperatura. Cogiendo esta idea como punto de partida, otro estudio [Mesut Toğaçar et al, 2020] demostró que la utilización de redes neuronales y aprendizaje automático puede ser la clave para la detección del cáncer de mama con imágenes térmicas y más aún aquellos modelos que utilizan mecanismos de atención, porque analizan la imagen en secciones en lugar de como un todo.

Este trabajo de fin de máster se enmarca en el proyecto de investigación PID2019-110686RB-I00, cuyo objetivo principal es el desarrollo de un sistema integral de ayuda a la decisión para el cribado del cáncer de mama. En el contexto de este proyecto, durante el curso académico 2022/2023 se realizó el trabajo de fin de máster "*Deep Learning y Mecanismos de Atención para la detección del cáncer de mama a través de imágenes térmicas*" [Aguilar, 2022], el cuál exploró la viabilidad de detectar el cáncer de mama a través de imágenes térmicas utilizando modelos con mecanismos de atención. Esta línea de investigación se ha llevado a cabo con un conjunto de datos limitado, compuesto por 260 imágenes térmicas de mamas, lo que supone un gran desafío a la hora de construir modelos con un rendimiento robusto. En esta ocasión la investigación se centra en estudiar la eficacia del aumento de datos mediante GANs analizando el impacto de esta técnica en los resultados anteriores del mejor modelo de detección (mecanismos de atención dura). La eficacia de este procedimiento tendría grandes beneficios en múltiples áreas donde la escasez de datos etiquetados es el principal obstáculo para la aplicación de modelos de aprendizaje profundo. No obstante, la generación de imágenes mediante GANs es una técnica que de igual manera requiere una gran cantidad de muestras en el conjunto de datos, lo que supone otro desafío.

Las redes generativas adversarias (GANs por sus siglas en inglés) son una serie de modelos generativos cuyo objetivo es generar muestras sintéticas con una alta similitud a las del conjunto de datos real. El entrenamiento de estas redes consiste en un juego competitivo de min-max, donde un modelo Generador G reproduce muestras a partir de ruido aleatorio y un modelo Discriminador D distingue las muestras sintéticas de las reales. Ambos modelos se entrenan de manera adversarial, donde el generador intenta engañar al discriminador creando muestras cada vez más verosímiles y el discriminador ajusta su aprendizaje para mejorar la capacidad de diferenciación.

El avance que han sufrido las redes generativas adversarias ha provocado que muchos estudios hayan impulsado el uso de estos modelos con el propósito de realizar un aumento de datos en conjuntos de datos limitados [Olaf Ronneberger et al., 2015]. Estos realizan una labor de investigación en imágenes médicas similares a las que se van a utilizar, demostrando la eficacia de la técnica en los resultados, como puede ser el caso del artículo [Saman Motamed et al., 2021] que utiliza imágenes de rayos X de pacientes con neumonías y COVID-19 para generar muestras sintéticas y aumentar la eficacia en la detección.

Es por ello que el presente proyecto continúa la línea de investigación PID2019-110686RB-I00 estudiando la eficacia del aumento de datos mediante redes generativas adversarias (GANs) en la detección del cáncer de mama a partir de imágenes térmicas. Para ello, se emplea un modelo predictivo que incorpora mecanismos de atención dura, el cuál demostró previamente ser el más robusto a la hora de predecir el cáncer de mama con el conjunto de datos propuesto.

1.2. Propuesta y objetivos

El propósito de este trabajo es generar imágenes sintéticas a través de GANs para realizar aumento de datos al limitado conjunto de imágenes térmicas y así investigar la eficacia de esta técnica utilizando un modelo de predicción basado en mecanismos de atención dura. Este objetivo principal se puede descomponer a su vez en varios subobjetivos:

- Investigar qué tipo de GAN es adecuado en este contexto e implementarlo.
- Definir un sistema de entrenamiento, recopilación de datos y evaluación para los GANs. Los sistemas GANs tienen el inconveniente de ser computacionalmente muy costosos e inestables durante el entrenamiento. Estos inconvenientes acentúan la importancia de definir una metodología para entrenar, evaluar y recoger datos, lo que permitirá comprobar el rendimiento de los modelos generativos.
- Afinación de hiperparámetros. Debido a las dificultades que presentan los GANs durante el entrenamiento, la afinación de hiperparámetros permitirá identificar que configuración de los modelos producen las imágenes más robustas. Sin la realización de este paso no se podría presenciar, con cierta precisión, el potencial del modelo propuesto.
- Definir un sistema para entrenar el modelo predictivo y evaluarlo. Dada la limitada cantidad de datos disponibles, es importante definir un flujo eficiente para la generación e incorporación de las muestras sintéticas, de forma que se evite cualquier desperdicio en el proceso. Tras entrenar el modelo GAN, las imágenes generadas se integran con el conjunto de datos original y a continuación se entrena y evalúa el modelo de detección. Este proceso se repite en varias ocasiones con distinto número de imágenes sintéticas

para evaluar el impacto en el rendimiento del modelo. Estos experimentos permitirán evaluar los resultados obtenidos teniendo en cuenta qué número de imágenes han sido más beneficiosas (o perjudiciales) en el entrenamiento del modelo.

- Analizar los datos recopilados y conclusión final. Dado que el trabajo de investigación que se está exponiendo entra dentro de un campo aún poco explorado, se deberá llevar a cabo un exhaustivo análisis e interpretación de los resultados obtenidos. Este subobjetivo es de vital importancia debido a que se encuentran una gran cantidad de métricas disponibles para cada casuística analizada y se debe condensar toda esa información para presentar una conclusión final rigurosa.

1.3. Metodología

Para la realización tanto de este proyecto como de su predecesor, es fundamental obtener un conjunto de datos de imágenes infrarrojas que posean un etiquetado. Para ello, se emplea la base de datos para la *Investigación Mastológica con Imágenes Infrarrojas (DMR-IR)*[Lincoln da Silva et al., 2014]. Con el fin de asegurar una coherencia con los resultados del proyecto anterior, se utiliza el preprocesamiento realizado en el mismo, el cuál consiste en un cribado para mantener aquellas imágenes realizadas de frente, la realización de recortes para que las mamas estén centradas, normalización y transformación a tamaño 56x56 píxeles. En cuanto a las técnicas de aumento de datos clásicas, se utilizan los volteos horizontales y los cambios de brillos.

Pasando a la generación de imágenes, el procedimiento consiste en entrenar dos modelos GAN, uno sobre muestras enfermas y otro sobre sanas. Cada modelo aprende únicamente las características de un tipo de muestra, concentrando su aprendizaje en este y permitiendo obtener mejores imágenes. Los sistemas generativos suelen presentar una serie de peculiaridades a la hora de entrenar, por lo que habrá que aplicar al conjunto de datos una serie de transformaciones que permitirán que este proceso se lleve de manera correcta, como por ejemplo el redimensionado de las imágenes a 128x128 píxeles. Una vez entrenados los modelos, se generan grupos de imágenes y se mantienen aquellos que sobrepasan un cierto valor de una métrica que identifica la robustez y similitud de las imágenes sintéticas comparadas con las reales. Tras esto, se mezclan las imágenes sintéticas y reales y se alimentan al modelo de detección para comprobar qué resultados arroja. Este proceso se lleva a cabo mediante un flujo muy riguroso que utiliza las imágenes de manera eficiente y optimiza la cantidad de ellas. De esta forma, se intenta que los GANs y el modelo predictivo posean las suficientes imágenes sin sacrificar en el proceso rigurosidad en la evaluación, ya que la longitud del conjunto de datos supone un gran desafío.

Para asegurar la rigurosidad de los datos obtenidos, el proceso anterior se realiza mediante

validación cruzada de 5 pliegues y esto a su vez se ejecuta 10 veces, lo que permite reducir el sesgo y obtener resultados más robustos. Se realizan varias pruebas con distinto número de imágenes para obtener una visión más profunda sobre la eficacia del aumento de datos mediante modelos generativos.

Finalmente, se realiza una análisis y conclusión exhaustivas gracias a las métricas recogidas durante la evaluación de los modelos generativos y el modelo predictivo. En el caso del sistema generativo, se recogen dos indicadores que marcan la similitud de las imágenes sintéticas con respecto a las reales (*KID Score y FID Score*) y la función de pérdida de ambos modelos, aunque no representa un indicador fiable para comparar rendimientos. En el caso del modelo predictivo, se analiza la media y la desviación típica de las siguientes métricas obtenidas en las 10 ejecuciones de cross-validation: exactitud, especificidad, precisión, exhaustividad y la puntuación F1; además de la curva ROC (valor AUC) y la matriz de confusión.

1.4. Estructura del documento

En este último apartado se indicará cuál es la estructura del trabajo presentado, permitiendo al lector la localización de los contenidos específicos abordados en cada capítulo. La estructura es la siguiente:

- Capítulo 1: Introducción. En el primer capítulo se definen las propuestas, el alcance y los objetivos de este proyecto, con el propósito de contextualizar el estudio antes de abordar los contenidos principales de este trabajo.
- Capítulo 2: Estado del arte. Este capítulo aborda las bases teóricas de las tecnologías utilizadas, incluyendo el aprendizaje profundo, los mecanismos de atención, las redes generativas adversarias, el Grad-CAM, el modelo StyleGAN, el aumento de datos, la afinación de hiperparámetros y las métricas de evaluación. Asimismo, se discutirán trabajos relacionados que servirán como referencia para entender las decisiones tomadas y los objetivos alcanzados.
- Capítulo 3: Métodos. Este capítulo recoge todas las acciones que se han llevado a cabo en el proyecto: estudio del conjunto de datos, elección de modelo GAN, proceso de entrenamiento de los GANs, metodología para la validación cruzada con el modelo predictivo y la afinación de hiperparámetros, entre otros aspectos relevantes. El objetivo de este consiste en justificar todas las decisiones tomadas durante la realización de este proyecto.
- Capítulo 4: Resultados. En este capítulo se exponen los resultados obtenidos, apoyados en gráficas y tablas que recogen cada una de las métricas relevantes. Para cada

experimento donde se ha generado una cierta cantidad de imágenes sintéticas, se presentarán todos los datos de forma que se pueda llegar a una interpretación, destacando los aspectos más importantes.

- Capítulo 5: Conclusiones y trabajos futuros. En este capítulo se resumen y discuten todos los procesos llevados a cabo en este trabajo, los resultados obtenidos y trabajos futuros, proporcionando indicaciones en caso de que se quiera continuar la línea de investigación de este proyecto en próximos trabajos.

Capítulo 2

Estado del Arte

En este capítulo se proporciona una base teórica sobre los conceptos utilizados en este estudio. En la primera sección se tratará el aprendizaje profundo, los mecanismos de atención, el Grad-CAM, las redes generativas adversarias (GANs), el StyleGAN, el aumento de datos, la afinación de hiperparámetros y las métricas de evaluación. En la segunda sección se recogerán dos investigaciones similares a esta: una donde se realiza aumento de datos con GANs para estudiar los resultados obtenidos en comparación con el aumento de datos clásico y la otra recoge técnicas y procedimientos para entrenar un GAN cuando se tiene un conjunto de datos limitado.

2.1. Fundamentos

Durante el siguiente segmento se recogen las bases teóricas de las tecnologías utilizadas durante el desarrollo de este proyecto, lo que permite demostrar en qué consisten y contextualizar el trabajo realizado. Tratando el aprendizaje profundo, los mecanismos de atención, el Grad-CAM, las redes generativas adversarias (GANs), el StyleGAN, el aumento de datos, la afinación de hiperparámetros y las métricas de evaluación

2.1.1. Aprendizaje profundo, mecanismos de atención y Grad-CAM

Las tecnologías presentadas en esta sección se van a explicar de manera breve y concisa con el objetivo de proporcionar el contexto necesario para comprender el modelo predictivo que se va a usar para evaluar este proyecto. Sin embargo, para obtener una visión más completa de los fundamentos de estas tecnologías, se remite al trabajo de fin de máster [Aguilar, 2022].

El aprendizaje profundo es una rama de la inteligencia artificial que consiste en el uso de redes neuronales artificiales capaces de aprender representaciones jerárquicas y abstractas a partir de datos complejos. Estas redes se componen de múltiples capas de neuronas, que

actúan de manera similar al cerebro humano. El aprendizaje se realiza mediante la propagación del error entre capas, lo que se conoce como propagación hacia atrás (*backpropagation* en inglés) y consiste en ajustar los pesos de cada neurona dependiendo del error cometido en la predicción.

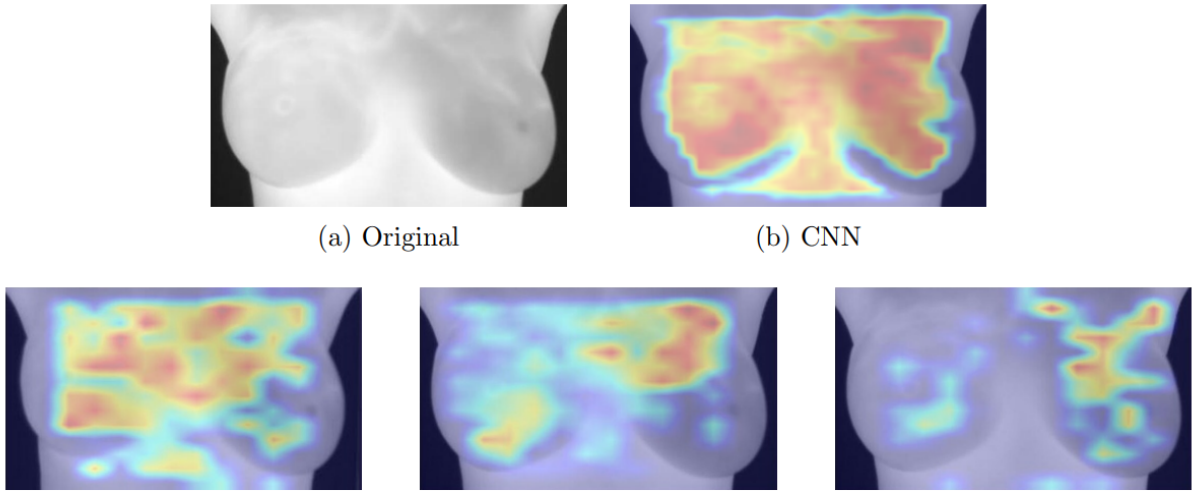
En el ámbito de las redes neuronales, aquellas con mayor relevancia son las redes neuronales convolucionales (CNN por sus siglas en inglés). Estas se caracterizan por aprender estructuras complejas sin necesidad de utilizar un gran número de parámetros, lo que se traduce en un entrenamiento más simple y eficiente. Asimismo, destacan por su potencia frente a conjuntos de datos con imágenes y texto. Las Redes Neuronales Convolucionales se componen de una capa de entrada, una serie de capas ocultas y una capa de salida. En la capa de entrada se preprocesan los datos, en las capas ocultas se produce la convolución (aplicar un filtro a las imágenes y extraer ciertas características del resultado) y en la capa de salida se ejecuta una función de activación (sigmoide, tangente hiperbólica, étc.) antes de devolver los resultados.

En este contexto, los mecanismos de atención constituyen una técnica del aprendizaje profundo que permite que las redes neuronales otorguen una cierta importancia a zonas destacadas de una imagen, en lugar de tratar la muestra de forma uniforme. Este método permite aumentar la importancia en ciertas regiones de la muestra obviando el resto, lo que mejora los resultados en muchas ocasiones. Hay 3 tipos de mecanismos de atención: auto-atención (observa la interacción entre cada parte resaltada para ver cuál es la que merece mayor atención), atención suave (asigna un peso a cada zona resaltada entre 0 y 1, indicando la cantidad de atención que recibirá) y atención dura (cada zona tendrá asignado 0 o 1, marcando al modelo si debe o no prestarle atención). [Alia Alshehri et al., 2022]

Para poder visualizar qué zonas han sido más influyentes en la predicción del modelo, existe la técnica *Grad-CAM*, introducida por primera vez en el estudio [Ramprasaath R. Selvaraju et al., 2019]. Consiste en generar explicaciones visuales para redes basadas en *CNN*. Este método se apoya en los gradientes del modelo, los cuáles se propagan hacia las capas convolucionales para generar un mapa de calor que indica las regiones con mayor peso en la predicción, es decir, qué zonas de la imagen ha tenido en cuenta el modelo en mayor medida. Asimismo, esta técnica tiene una metodología de localización discriminatoria por clases, por lo que dependiendo de cada clase obtendremos un mapa de calor u otro. En la fig. 2.1 se puede observar el método Grad-CAM aplicado a una imagen de la paciente 373 con cada uno de los modelos entrenados en el proyecto [Aguilar, 2022].

2.1.2. Redes Generativas Adversarias (GANs)

Las redes generativas adversarias (GANs) constituyen un sistema generativo donde se entrenan 2 redes neuronales compitiendo entre síntesis: un modelo generador G que reproduce



(a) Original (b) CNN

(c) CNN + Auto-atención (d) CNN + Atención suave (e) CNN + Atención dura

Figura 2.1: Método Grad-CAM usando los modelos entrenados sobre la paciente 373. *Fuente:* [Aguilar, 2022]

la distribución de los datos proporcionados y un modelo discriminador D que estima la probabilidad de que cada imagen sea originada por el generador G o, en su defecto, pertenezca al conjunto de datos de reales. El objetivo de este sistema consiste en generar muestras con una gran similitud a los datos de entrada al cabo de varias iteraciones.

El entrenamiento de un GAN consiste en un juego de suma cero entre los dos modelos explicados anteriormente, donde G pretenderá maximizar la pérdida del modelo D y viceversa. En este tipo de juegos cada jugador tratará de minimizar la puntuación del otro. EEn este proceso G trata de engañar a D generando muestras con una distribución muy similar al conjunto de datos, mientras que D mejora su capacidad de detección para diferenciar eficientemente las imágenes sintéticas.

El modelo G tiene como entrada ruido aleatorio, de forma que posea una semilla o punto de partida para generar las muestras, mientras que el modelo D recibe un conjunto de muestras donde están mezcladas reales y generadas. Por tanto, el generador no visualizará directamente las imágenes en ningún momento, sino que aprenderá a generarlas a raíz de la función de pérdida del discriminador. Cuando finaliza el proceso de entrenamiento, se puede utilizar el modelo G para crear N imágenes que posean una distribución parecida o casi idéntica a los datos de entrada. En la fig. 2.2 se puede observar un esquema del proceso de entrenamiento de ambos modelos.

Este sistema generativo cuenta con una serie de ventajas y desventajas:

- **Ventajas**

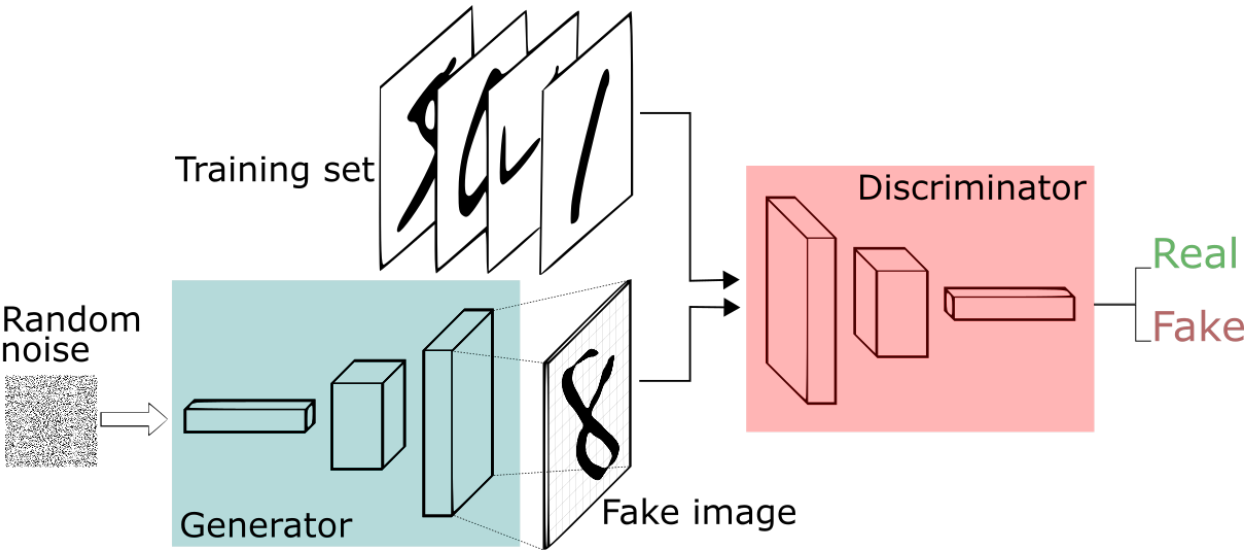


Figura 2.2: Proceso de entrenamiento de los GANs. *Fuente: Sthalles.Github*

- Existen muchas variantes de GANs con distintas características y aplicaciones. Los GANs presentan un gran rendimiento en múltiples campos como la transferencia de estilo, la clasificación o la superresolución de imágenes, entre otros. Esto, junto con la gran atención recibida a lo largo de los años, ha propiciado la aparición de variantes [Hamed Alqahtani et al., 2019] tales como *StyleGAN*, que realiza transferencia de estilo [Tero Karras et al., 2018], *GRANs*, que emplea redes convolucionales recurrentes [Daniel Jiwoong Im et al., 2016], o *DCGAN*, basado en redes convolucionales orientado al aprendizaje no supervisado [Alec Radford et al., 2015].
- Como ya se indicó anteriormente, el generador no recibe el conjunto de datos en ningún momento, sino que entrena mediante el flujo del gradiente del discriminador. Esto significa que las muestras generadas finalmente serán nuevas imágenes y no copias de los datos de entrada. [Ian J. Goodfellow et al., 2014]
- Obtiene mejores resultados en cuanto a calidad de las muestras comparado con otros modelos generativos, como el Autocodificador Variacional (*Variational Autoencoder* - *VAE* por sus siglas en inglés) [Sam Bond-Taylor et al., 2021].

▪ **Desventajas**

- La principal desventaja de los sistemas GANs es la inestabilidad. Estos son conocidos por tener un proceso de entrenamiento tumultuoso debido a que en muchas ocasiones incurren en fallos al converger o en colapso de modo, lo que conlleva que el sistema alcance un punto irrecuperable y las muestras generadas sean ineficientes. [Hamed Alqahtani et al., 2019]
- No dispone de métricas de evaluación preestablecidas que permitan conocer de

manera directa cómo está actuando el sistema y poder realizar comparaciones con otros modelos. A lo largo de los años se han propuesto algunos índices para evaluar el comportamiento tales como la puntuación FID (*Fréchet inception distance*) [Martin Heusel et al., 2017] o la puntuación KID (*Kernel inception distance*) [Mikołaj Bińkowski et al., 2018], la cuál se basa en el FID añadiendo resistencia a sesgos cuando se estudian conjuntos de datos reducidos.

- Requieren de una gran cantidad de recursos computacionales. La razón principal de esto es que se entrenan dos modelos en cada iteración.

En cuanto al entrenamiento de los GANs, hay dos conceptos de gran relevancia: la convergencia y el colapso de modo. Por un lado, se considera que un sistema ha alcanzado la convergencia cuando ninguno de los dos modelos puede realizar acciones que mejoren su pérdida (o empeoren la del otro). Esta situación se conoce como equilibrio de Nash (*Nash Equilibrium*) y consiste en un estado donde generador produce muestras tan verosímiles que el discriminador no puede diferenciarlas. El equilibrio de Nash es la situación que se espera alcanzar cuando se entrena un sistema GAN durante el suficiente tiempo [Ian J. Goodfellow et al., 2014]. Sin embargo, algunos estudios como [Farzan Farnia et al., 2020] indican que esta situación es prácticamente ideal y que en muchas ocasiones sólo se puede alcanzar un estado próximo al equilibrio de Nash. Por tanto, se conoce como fallo de convergencia al estado en el que el sistema no ha logrado encontrar un equilibrio de Nash y la función de pérdida del discriminador es cercana a 0 mientras que la del generador continúa aumentando. A partir de este momento, G produce "muestras inservibles" y el sistema alcanza un punto de no retorno [Brownlee, 2021].

Por otro lado, el colapso de modo consiste en la reproducción de manera muy eficaz, por parte del generador, de ciertas clases del conjunto de datos sin tener en cuenta el resto de ellas [TOPAL, 2023]. Esto produce que el discriminador no sea capaz de identificar cuáles son reales o generadas, lo que conlleva a que el generador reproduzca únicamente muestras con una distribución similar a la porción que ha aprendido de manera eficiente. En la fig. 2.3 se puede observar un ejemplo de esta situación, donde las imágenes generadas solo pertenecen a un subconjunto de los datos: los números 0 y 1, mientras que el conjunto de datos consiste en los números del 0 al 9.

Los fundamentos de los GANs tratados en esta sección fueron recogidos por primera vez en un estudio de 2014 titulado *Generative Adversarial Nets*[Ian J. Goodfellow et al., 2014], el cuál descubrió la potencia de los modelos GANs. Desde entonces, los sistemas GANs han cobrado una gran relevancia y son usados hoy en día en miles de aplicaciones.

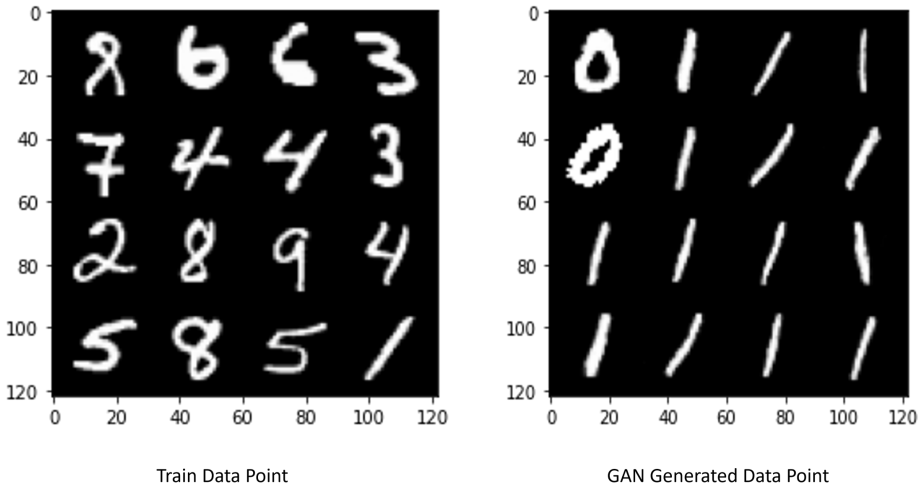


Figura 2.3: Colapso de modo en los GANS. A la izquierda, el conjunto de datos. A la derecha, las imágenes del Generador. *Fuente: Addressing mode collapse in GANs*

2.1.3. StyleGAN

Tras la publicación del estudio mencionado anteriormente [Ian J. Goodfellow et al., 2014], surgieron una serie de investigaciones sobre GANs con un mayor rendimiento y nuevas características añadidas sobre el sistema de la idea original. Gracias a esto, nacieron modelos como el *cGAN* (*Conditional Generative Adversarial Nets*) que diseña un sistema donde el generador aprende a reproducir imágenes de distintas clases del conjunto de datos, de forma que se genera un tipo de imagen sintética u otra dependiendo de la etiqueta recibida por este [Mehdi Mirza et al., 2018].

En 2018 apareció una publicación [Tero Karras et al., 2018] donde se recogía otro sistema generativo llamado *StyleGAN*. Este sistema se caracteriza por introducir un enfoque innovador al separar la representación del contenido y el estilo visual, de forma que introduce un mapeo intermedio antes de introducir el vector latente en el generador. Esto quiere decir que este sistema incorpora una red neuronal completamente conectada que sirve como intermediario entre el generador y el ruido aleatorio, lo cuál permite controlar distintos aspectos visuales de la imagen generada gracias a otra técnica utilizada: normalización de instancia adaptativa (*AdaIN - Adaptative Instance Normalization*). El modelo generador del *StyleGAN* consiste en dos redes unidas entre sí: la red de mapeo (*mapping network*) y la red de síntesis (*synthesis network*), como se puede ver en la fig.2.4 b. Tradicionalmente, los generadores reciben el ruido aleatorio a través de una capa de entrada (fig. 2.4 a); sin embargo, este modelo omite esa capa para introducir una red de 8 capas completamente conectadas (*FC - Fully Connected*), creando un espacio latente intermediario W. Un espacio latente consiste en una representación comprimida de los datos que conserva las características principales de los mismos [Bergmann, 2018]. Esto permite variar distintos aspectos de la salida del generador a través de AdaIN tales como, por ejemplo, añadir gafas a una persona, aumentar la edad,

étc. [Tero Karras et al., 2018]. En este apartado se detallarán los fundamentos teóricos de *AdaIN*.

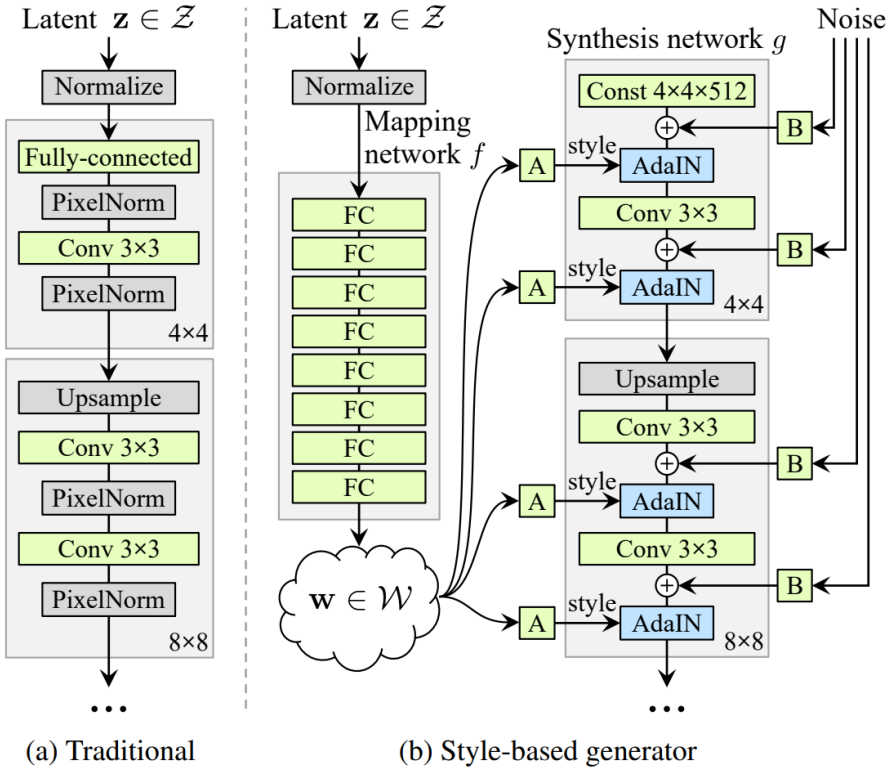


Figura 2.4: (a) Estructura tradicional del GAN. (b) Estructura del StyleGAN. Fuente: [Tero Karras et al., 2018].

La segunda red, *synthesis network*, consiste en una serie de capas de convolución donde el tamaño de la imagen generada comienza en 4x4 y se duplica con cada capa hasta alcanzar la resolución final. En cada una se introducen las variaciones definidas en el espacio latente W a través de AdaIN, de forma que se controla la salida obtenida por el generador. Tras cada convolución, asimismo, se inserta ruido gaussiano, lo que introduce una variación estocástica a las imágenes. Gracias a esto se producen pequeñas modificaciones orgánicas en las imágenes aunque exista una misma configuración del espacio latente. Esto se puede observar en la fig. 2.5 b, donde distintos ruidos gaussianos provocan que el pelo de cada persona se coloque en una distribución diferente a pesar de que ambas caras se mantengan idénticas a lo largo de las generaciones. En la fig. 2.5 c se puede observar la variación de las imágenes sintéticas a lo largo de 100 iteraciones con la misma configuración del espacio latente, donde se identifica que la cara ha presentado una variación nula mientras que ciertos detalles como el pelo o la ropa presentan las variaciones más altas [Tero Karras et al., 2018].

Tras sentar las bases teóricas del sistema *StyleGAN*, se va a profundizar a continuación en la normalización adaptativa de instancia *AdaIN*, ya que constituye una parte fundamental



(a) Generated image (b) Stochastic variation (c) Standard deviation

Figura 2.5: Ejemplos de variación estocástica. a) Dos imágenes sintéticas b) Ampliación de una parte de la imagen con distintos ruidos gaussianos c) Desviación estándar de 100 iteraciones. Fuente: [Tero Karras et al., 2018].

de este. *AdaIN* es utilizado en inteligencia artificial como un método rápido y efectivo para transferir el estilo de una imagen al contenido de otra (transferencia de estilo) [Xun Huang et al., 2017]. La normalización de instancia consiste en normalizar cada muestra del conjunto para que posea una distribución gaussiana, a diferencia de la normalización por conjuntos (*batch normalization*) que obtiene media y desviación del conjunto completo. Según [Xun Huang et al., 2017], la normalización de instancia permite que cada muestra se mantenga invariable en contenido y a su vez pueda ser transferida a otro estilo de imagen. Partiendo de este principio, *AdaIN* propone una normalización de instancia adaptativa donde recibe un contenido x y un estilo y y alinea las medias y varianzas de x para coincidir con las de y, pero realizando esta operación en cada canal de la muestra. Es decir, para una imagen a color, realiza esta alineación en cada uno de los 3 canales (*RGB* - rojo, verde, azul) [Xun Huang et al., 2017]. La fórmula del AdaIN es la siguiente [Xun Huang et al., 2017]:

$$AdaIN(x, y) = \sigma(y)(\frac{x - \mu(x)}{\sigma(x)}) + \mu(x)$$

siendo σ la desviación estándar y μ la media.

Esta operación permite transferir los estilos de una imagen al contenido de otra, como se puede observar en la fig. 2.6 en la tercera columna, donde se parte de unos estilos (reflejados en la primera columna) y al aplicar esta técnica a las imágenes (segunda columna) se mantiene el mismo contenido pero con el estilo aplicado. Esta imagen recoge distintas técnicas

de aplicación de estilos, comparando la potencia de AdaIN (tercera columna) con el resto de técnicas: cuarta columna [Tian Qi Chen et al., 2016], quinta columna [Dmitry Ulyanov et al., 2016] y sexta columna [Leon A. Gatys et al., 2016]. El potencial ofrecido por *AdaIN* al modelo *StyleGAN* permite que mediante el espacio latente W se puedan modificar el resultado de las imágenes sintéticas, para así obtener imágenes con distintas características (personas con gafas, pelo, étc.).

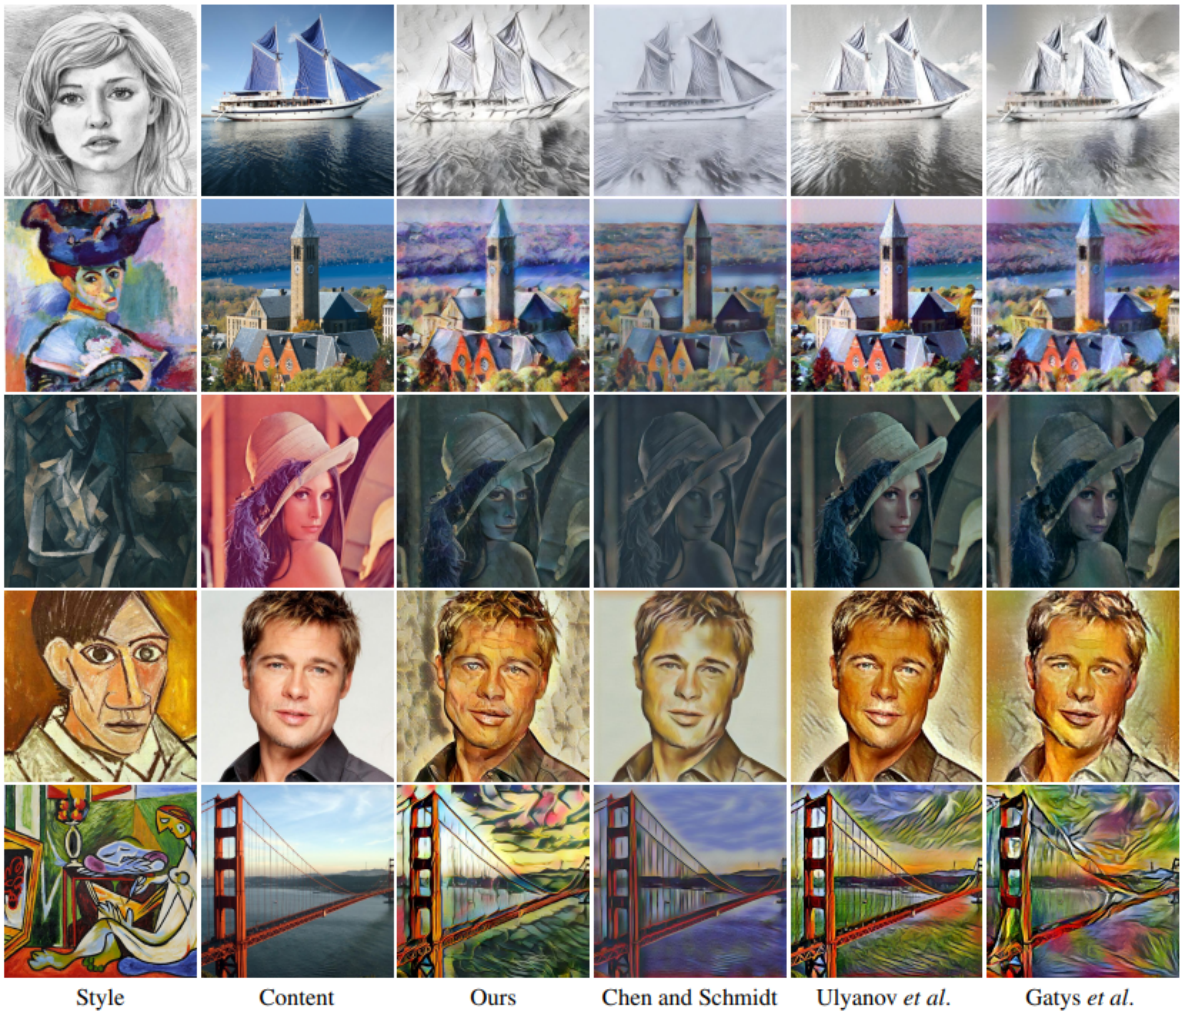


Figura 2.6: Ejemplos de técnicas de transferencia de estilo. En la primera columna se encuentra el estilo a aplicar. En la segunda, la imagen cuyo estilo será aplicado. La tercera recoge la aplicación del estilo mediante AdaIN en el proyecto [Xun Huang et al., 2017]. La cuarta recoge el estilo aplicado a través de la técnica detallada en [Tian Qi Chen et al., 2016]. La quinta, con la técnica descrita en [Dmitry Ulyanov et al., 2016] y finalmente, la última columna mediante el procedimiento de [Leon A. Gatys et al., 2016]. Fuente: [Xun Huang et al., 2017]

StyleGAN posee además otra ventaja: su función de pérdida, *Wasserstein*. Esta función determina la verosimilitud de las imágenes sintéticas en lugar de calcular si el discrimina-

dor puede diferenciarla o no de una real. Bajo este contexto, la figura del discriminador se denomina *crítico*, aunque en esta memoria se va a obviar esta designación para evitar confusiones. Esta función mide la distancia entre las distribuciones de imágenes reales y sintéticas para evaluar la verosimilitud. Una de sus principales ventajas es que proporciona una gran estabilidad y una convergencia rápida en muchos casos. Según [Martin Arjovsky et al., 2017], entrenar un *WGAN* (un GAN que contiene como función de pérdida *Wasserstein*) no requiere mantenimiento a la hora de conseguir un equilibrio entre el generador y el discriminador, lo que se traduce en menos situaciones como el colapso de modo, propiciando una mayor estabilidad. Las funciones de pérdida del generador y del discriminador se calculan de la siguiente manera:

- Pérdida del discriminador: [media de la puntuación del discriminador en imágenes reales] - [media de la puntuación del discriminador en imágenes sintéticas]
- Pérdida del generador: - [media de la puntuación del discriminador en imágenes sintéticas]

Esta fórmula conlleva que una mayor pérdida del discriminador sea una menor pérdida para el generador. *Wasserstein* intentará que estos valores se mantengan alejados para un mejor entrenamiento. A pesar de todas las ventajas, *Wasserstein* no es una función que permita comparar el rendimiento entre GANs ni conocer con certeza si la ejecución actual es óptima. Debido a la relación entre las pérdidas de discriminador y generador, un valor aceptable de la pérdida *Wasserstein* podrá ser positivo, negativo o cercano a 0 [Brownlee, 2019], dependerá de cada situación.

Tras esta primera iteración del sistema *StyleGAN* recogida en [Tero Karras et al., 2018] han aparecido otras versiones mejorando algunos aspectos, como *StyleGAN 2*, que modifica la normalización realizada por el generador y el crecimiento progresivo [Tero Karrase et al., 2020] o *StyleGAN 3* que mejora la segunda iteración modelando un sistema con mayor independencia de las coordenadas de los píxeles [Tero Karras et al., 2021].

2.1.4. Aumento de datos

El aumento de datos es una técnica que consiste en generar nuevas muestras de un conjunto de datos a través de aplicar transformaciones tales como volteos, rotaciones, o correcciones de color. En la fig. 2.7 se pueden observar algunas de estas transformaciones. Esta técnica es ampliamente utilizada en la inteligencia artificial sobre aquellos conjuntos de datos que poseen un número escaso de muestras, con el objetivo de evitar el sobreentrenamiento. Cuando un modelo recibe un conjunto de datos reducido, tiende a sobreentrenar, limitando la capacidad de generalización al aplicarlo sobre muestras no vistas anteriormente. Por ello,

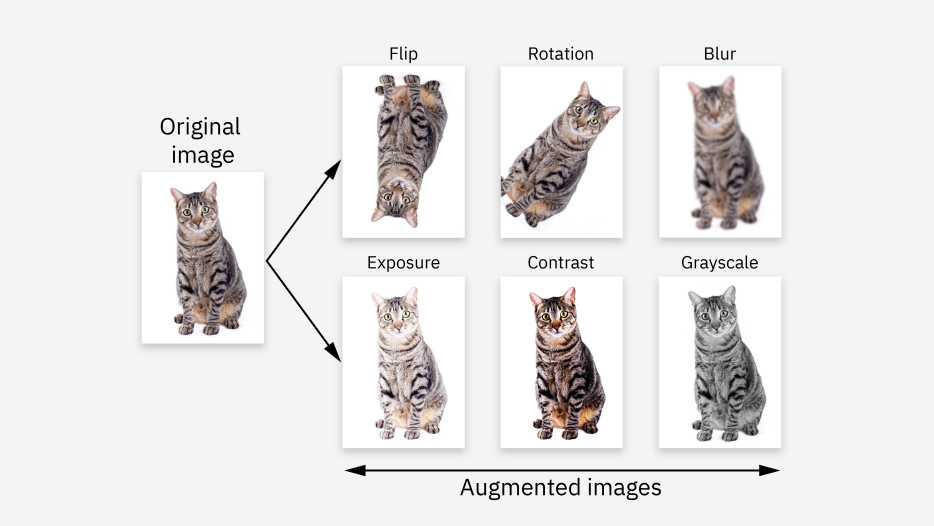


Figura 2.7: Algunas de las transformaciones utilizadas en el aumento de datos. Fuente: IBM - Data Augmentation

el aumento de datos permite que los modelos obtengan resultados más robustos favoreciendo una mayor generalización.

Dado el potencial de los sistemas GANs, se ha propuesto su uso como una técnica de aumento de datos a través de la generación de imágenes sintéticas. A diferencia de las transformaciones mencionadas anteriormente, las imágenes que se generan poseen una distribución similar al conjunto real sin llegar a ser idénticas, lo que mitiga la posibilidad de que el modelo sobreentrene.

2.1.5. Afinación de hiperparámetros

La afinación de hiperparámetros es una técnica que consiste en ejecutar múltiples instancias de un modelo modificando parámetros en cada una (ratio de aprendizaje, número de épocas, étc.). El objetivo es determinar qué configuración optimiza el rendimiento del modelo. Para llevar a cabo esta técnica se utiliza el mismo subconjunto de datos de entrenamiento y prueba con cada ejecución, para asegurar la igualdad de condiciones y observar cuál obtiene mejores resultados. La afinación de hiperparámetros se puede abordar de varias formas, pero se destacan 3:

- Busqueda Aleatoria (*Random Search*). Selecciona valores aleatorios para cada parámetro seleccionado a estudiar. [Wikipedia, 2025b]
- Búsqueda en cuadrícula (*Grid Search*). Se definen una serie de valores para cada parámetro y se exploran todas las posibles combinaciones. [Wikipedia, 2025b]
- Optimización Bayesiana (*Bayesian Optimization*). Este método busca optimizar los valores de los parámetros con el objetivo de alcanzar la configuración óptima. [Wikipedia,

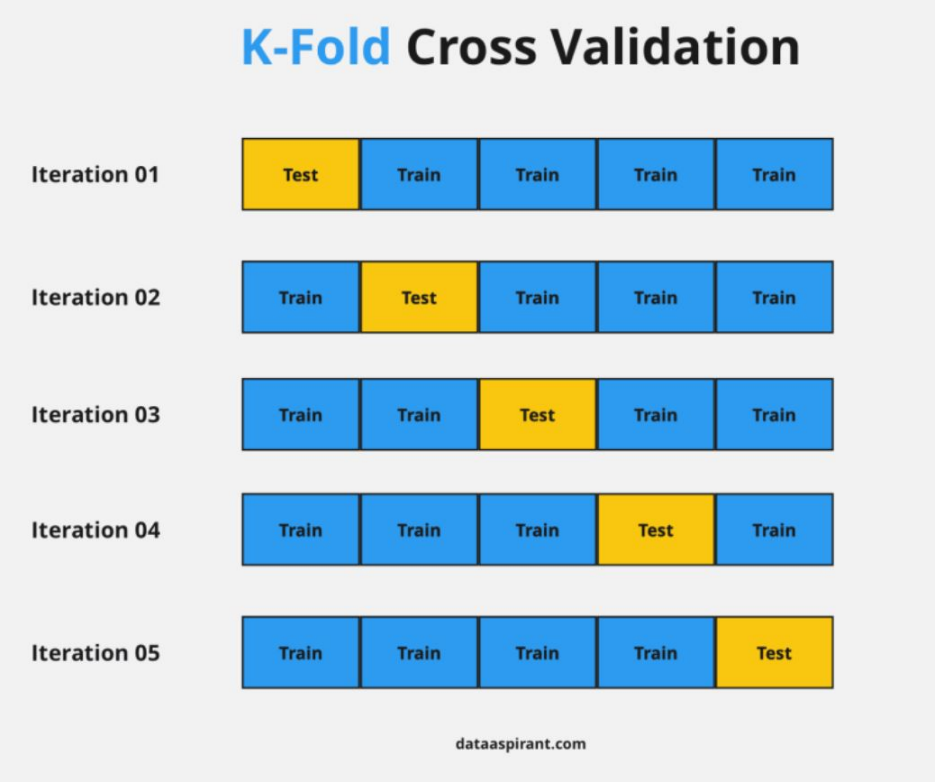


Figura 2.8: Esquema de la validación cruzada

2025b]

2.1.6. Métricas de evaluación

Antes de abordar los fundamentos teóricos de las métricas de evaluación utilizadas en este proyecto, es conveniente introducir el concepto de validación cruzada, dado que forma parte esencial en las métricas que se recogen durante la ejecución del modelo.

La validación cruzada es una técnica utilizada para evaluar el rendimiento de un modelo reduciendo la dependencia de los resultados respecto a una única partición del conjunto de datos. Esta técnica consiste en realizar varias iteraciones con distintas particiones del conjunto de datos, evaluando el modelo y calculando la media aritmética de las métricas obtenidas. Este procedimiento resulta útil cuando se evalúa un modelo predictivo, ya que permite estimar con mayor fiabilidad el comportamiento en una situación real [Wikipedia, 2023]. Como se muestra en la fig. 2.8, al definir un número k de pliegues (*folds*), el conjunto de datos se dividirá en k particiones, asignando una de ellas al conjunto de prueba y el resto al entrenamiento. Este proceso se repetirá k veces, rotando estas asignaciones en cada iteración hasta cubrir todas las combinaciones posibles.

A continuación, se presentan las métricas de evaluación utilizadas en este proyecto, muchas de las cuáles se utilizarán en la validación cruzada para mitigar sesgos y obtener re-

sultados más robustos. Debido a que el objetivo de este trabajo es estudiar el impacto del aumento de datos mediante GANs sobre el modelo del estudio previo, se han mantenido las mismas métricas de evaluación, lo que facilita la comparación entre ambos enfoques[Aguilar, 2022].

- Matriz de Confusión: proporciona una visión general del modelo de clasificación, identificando de manera rápida y concisa la cantidad de predicciones correctas e incorrectas de cada clase. A partir de esta se derivan las siguientes métricas:
  - Verdaderos Positivos. (*TP - True Positives*). Casos en los que el modelo predice correctamente a una instancia positiva.
  - Verdaderos Negativos (*TN - True Negative*). Casos en los que el modelo predice correctamente una instancia negativa.
  - Falsos Positivos (*FP - False Positives*). Casos en los que el modelo predice de manera incorrecta una instancia negativa.
  - Falsos Negativos (*FN - False Negatives*). Casos en los que el modelo predice de manera incorrecta una instancia positiva.
- Exactitud (*Accuracy*): representa la proporción de predicciones correctas realizadas en relación con el total de predicciones.

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- Especificidad (*Specifity*): representa la capacidad del modelo para identificar correctamente instancias negativas.

$$specifity = \frac{TN}{TN + FP}$$

- Precision (*Precision*): representa la proporción de predicciones positivas correctas en relación con todas las predicciones positivas.

$$precision = \frac{TP}{TP + FP}$$

- Exhaustividad (*Recall*): mide la capacidad del modelo de identificar muestras positivas.

$$recall = \frac{TP}{TP + FN}$$

- Puntuación F1 (*F1 Score*): combina la precisión y la exhaustividad en un solo valor que refleja el equilibrio entre ambas métricas.

$$F1 - score = 2\frac{PrecisionRecall}{(Precision + Recall)}$$

- Curva AOC y Área bajo la Curva (AUC): la curva ROC es una representación gráfica que muestra la tasa de verdaderos positivos frente a la tasa de falsos positivos para diferentes umbrales de clasificación. El área bajo la curva (AUC) mide la capacidad discriminatoria del modelo; y un AUC más alto indica un mejor rendimiento de clasificación.

Tras presentar las bases teóricas de las métricas de evaluación para el modelo predictivo, se introducen a continuación las métricas utilizadas para evaluar la calidad de las imágenes sintéticas: las puntuaciones FID y KID. Tal y como se indicó anteriormente, uno de los problemas principales de los GANs es la evaluación de su rendimiento para realizar comparaciones con otras ejecuciones. Para solucionar este problema, en 2017 se modeló la puntuación FID (*Fretchet Inception Distance*) [Martin Heusel et al., 2017] que mejora el *Inception Score* (*IS*) y permite a través de una medida de distancia evaluar la verosimilitud de las imágenes sintéticas. Esta procesa las imágenes a través del modelo *Inception v3*, seleccionando la función de activación de la última capa para los dos conjuntos de datos. A continuación, se compara la media y covarianza de cada uno con la distancia de la fórmula [Wikipedia, 2025a]:

$$d_F(N(\mu, \sum), N(\mu', \sum')^2 = ||\mu - \mu' + ||_2^2 + TR(\sum + \sum' - 2(\sum \sum')^{\frac{1}{2}})$$

donde N es la distribución normal multivariante, μ la media, $\sum$ la matriz de covarianza y TR la traza de la matriz.

Mencionar que *Inception v3* pertenece a una familia de redes convolucionales entrenadas con el objetivo de realizar tareas en el ámbito de la visión por computador [Christian Szegedy et al., 2015]. Este índice presenta un problema y es que requiere de una gran cantidad de muestras para un funcionamiento eficiente, produciendo valores sesgados en conjuntos de datos reducidos. Ante esto, en 2018 se introdujo un índice que soluciona este problema, el KID (*Kernel Inception Distance*) [Mikołaj Bińkowski et al., 2018], el cuál es utilizado principalmente en este proyecto y se calcula a través de:

$$KID = MMD(f_{real}, f_{fake})^2$$

siendo MMD la media de la discrepancia máxima, f_{real} las características obtenidas del conjunto de datos real y f_{fake} las características obtenidas del conjunto de datos sintéticos.

La función MMD emplea de igual manera el modelo *Inception v3* para el cálculo de la discrepancia.

2.2. Trabajos relacionados

En esta sección se presentan dos investigaciones relevantes que guardan una estrecha relación con el estudio actual, siendo fundamentales para su desarrollo. En primer lugar, se analiza un estudio que realiza aumento de datos mediante GANs y compara los resultados con aumento de datos tradicional en un modelo predictivo [Antreas Antoniou et al., 2018]. En segundo lugar, se discute un estudio que propone un sistema para entrenar un GAN en un conjunto de datos reducido. Este último proyecto ha tenido una gran influencia en la realización de este trabajo [Tero Karras et al., 2020].

2.2.1. Aumento de datos con GANs para modelo de predicción

En 2018 se publica el estudio [Antreas Antoniou et al., 2018] cuyo objetivo es comparar la eficacia del aumento de datos mediante técnicas tradicionales y mediante GAN, utilizando un conjunto de imágenes de caracteres manuscritos y de rostros humanos . En esta investiganción se utiliza un GAN llamado DAGAN (*Data Augmentation Generative Adversarial Networks*), el cuál reproduce los caracteres manuscritos como se muestra en la fig. 2.9. La idea de este estudio es comparar los resultados obtenidos por un modelo predictivo usando ambas técnicas de aumento de datos y así validar el potencial de los GANs en este ámbito.

La arquitectura de la red DAGAN integra distintos componentes funcionales y arquitectónicos, incluyendo estructuras como UNet (comúnmente utilizado en la segmentación de imágenes) y ResNet (empleado en modelos de transferencia de aprendizaje) junto con operaciones de redimensionado superior o inferior (*upsacaling y downscaling*), capas convolucionales, función de activación *Leaky RELU*, renormalización del conjunto y *dropout* (evita el sobreentrenamiento). Para profundizar acerca de las características de este modelo, se remite al documento original [Antreas Antoniou et al., 2018].

Para el entrenamiento y evaluación del modelo se emplearon 3 conjuntos de datos: Omniglot (fig. 2.9), EMNIST (escritura a mano de dígitos entre 0 y 9) y VGG-Face (fotos de rostros humanos centrados). En la tabla 2.1 se observan los resultados obtenidos para cada conjunto. Para cada uno de ellos, el modelo predictivo se entrena y evalúa integrando técnicas de aumento de datos tradicionales al conjunto original (columna *Experiment ID* denominado como *Standard*) y a continuación se realiza el mismo proceso introduciendo imágenes generadas por DAGAN (*DAGAN_ Augmented*). Esta operación se repite en varias iteraciones aumentando el número de muestras por clase (*Sample per Class*). Como se puede observar, los resultados obtenidos indican que el aumento de datos por imágenes sintéticas mejora el rendimiento del modelo predictivo en mayor medida que las técnicas tradicionales de aumento de datos (la negrita indica el mejor resultado). Cada valor presentado en la tabla supone la media de 5 ejecuciones independientes, para mitigar sesgos. Este estudio permite

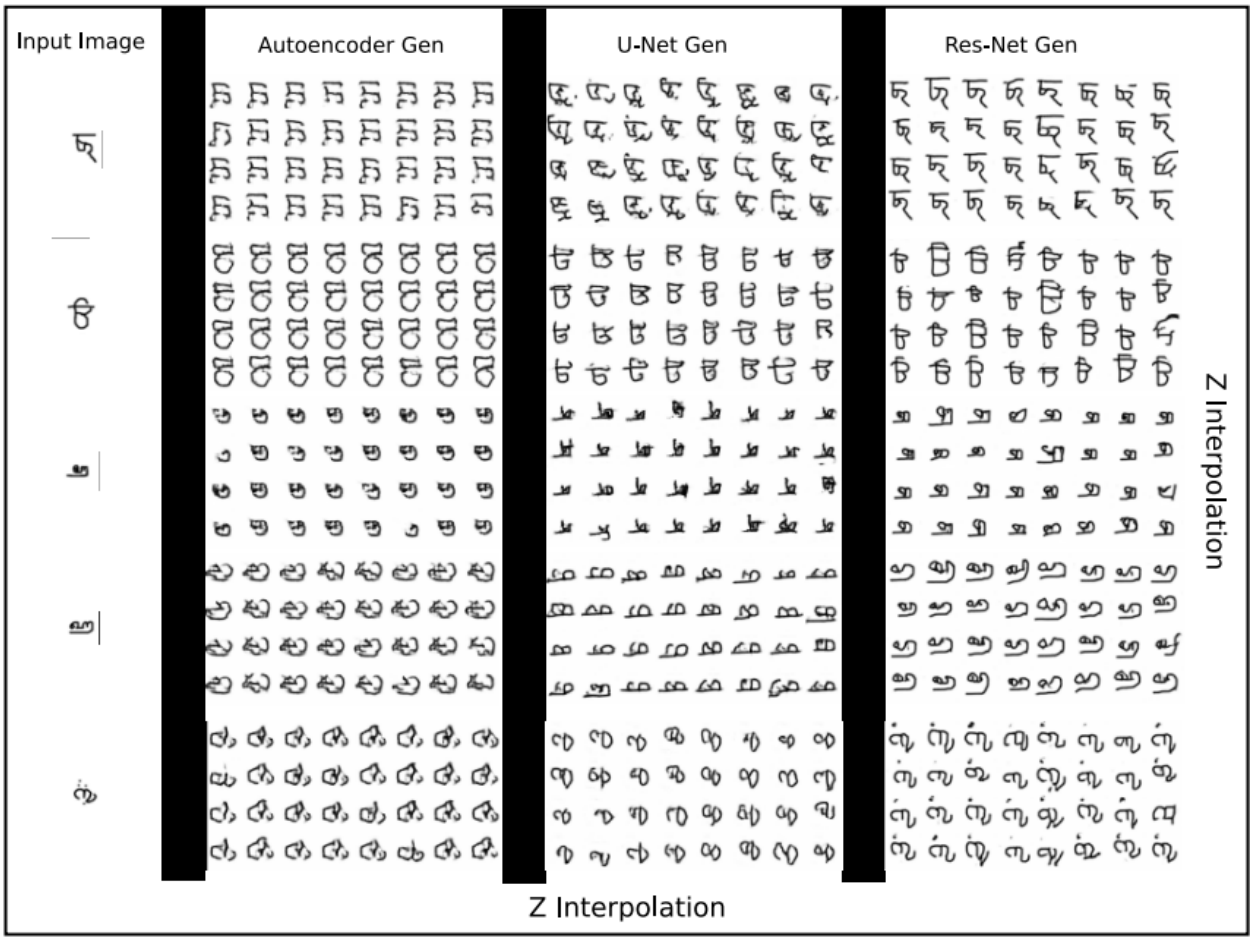


Figura 2.9: Muestras generadas por DAGAN del conjunto de datos con distintas arquitecturas. En la columna de la izquierda se muestra la imagen original, en la segunda las muestras generadas con una arquitectura de autoencoder, en la tercera con U-Net (*red de segmentación de imágenes*) y la cuarta con Res-Net (*transfer learning*).
[Antreas Antoniou et al., 2018]

respaldar el proyecto actual en cuanto a que evidencia la viabilidad y la eficacia del aumento de datos mediante generación sintética de imágenes.

2.2.2. Entrenamiento de GANs con datos limitados

En 2020 se publica el trabajo [Tero Karras et al., 2020] titulado *Training Generative Adversarial Networks with Limited Data* en el que se propone una técnica de aumento de datos adaptativo que estabiliza el entrenamiento de GANs en conjuntos de datos limitados. El método propuesto no requiere cambiar la función de pérdida ni la arquitectura de la red y es probado en diferentes conjuntos de datos para demostrar su eficacia.

Durante el entrenamiento de los modelos GANs, el seguimiento continuo del índice KID o FID permite identificar el punto en el que el rendimiento comienza a deteriorarse, evidenciado por un incremento en dicho valor (mayor valor del índice, imágenes menos verosímiles).

Omniglot DAGAN Augmented Classification		
Experiment ID	Samples Per Class	Test Accuracy
Omni_5_Standard	5	0.689904
Omni_5_DAGAN_Augmented	5	**0.821314**
Omni_10_Standard	10	0.794071
Omni_10_DAGAN_Augmented	10	**0.862179**
Omni_15_Standard	15	0.819712
Omni_15_DAGAN_Augmented	15	**0.874199**
EMNIST DAGAN Augmented Classification		
Experiment ID	Samples Per Class	Test Accuracy
EMNIST_Standard	15	0.739353
EMNIST_DAGAN_Augmented	15	**0.760701**
EMNIST_Standard	25	0.783539
EMNIST_DAGAN_Augmented	25	**0.802598**
EMNIST_Standard	50	0.815055
EMNIST_DAGAN_Augmented	50	**0.827832**
EMNIST_Standard	100	0.837787
EMNIST_DAGAN_Augmented	100	**0.848009**
Face DAGAN Augmented Classification		
Experiment ID	Samples Per Class	Test Accuracy
VGG-Face_Standard	5	0.0446948
VGG-Face_DAGAN_Augmented	5	**0.125969**
VGG-Face_Standard	15	0.39329
VGG-Face_DAGAN_Augmented	15	**0.429385**
VGG-Face_Standard	25	0.579942
VGG-Face_DAGAN_Augmented	25	**0.584666**

Tabla 2.1: Resultados del modelo de predicción con los distintos conjuntos de datos. La primera columna supone el experimento, la segunda las muestras para cada clase y la tercera la precisión obtenida en el conjunto de prueba. Los resultados mostrados pertenecen a la media de 5 ejecuciones independientes.

Este aumento se produce debido al sobreentrenamiento. Cuanto menor es el conjunto de datos, más temprano se produce esta situación. El estudio recogido propone una manera de mitigar esta situación cuando el conjunto de datos es reducido, empleando aumentos de datos versátiles que eviten una sobreconfianza del discriminador.

Las técnicas tradicionales de aumento de datos tales como la rotación, la modificación del brillo o el desenfoque, entre otros, presentan limitaciones a la hora de ser utilizadas durante el entrenamiento de modelos generativos. En concreto, estas transformaciones pueden llegar a filtrarse a las imágenes sintéticas, observando en las nuevas imágenes las modificaciones mencionadas. Para abordar esta problemática, el estudio propone la estructura indicada en la fig. 2.10, que consiste en definir un parámetro p (entre 0 y 1) que recoja la posibilidad de que se apliquen las técnicas de aumento de datos predefinidas (AUG - rectángulo azul), aplicando este parámetro en todas las imágenes que recibe el discriminador [Tero Karras et al., 2020]. Aunque este enfoque parezca contraintuitivo, su eficacia reside en que todas las imágenes que el discriminador recibe pueden llevar transformaciones aplicadas, por lo que este no es capaz de diferenciar imagen real o sintética simplemente mirando si posee alguna. Ante esto, el generador, por tanto, deberá modificar su aprendizaje para no incluir las transformaciones, ya que el filtro "Aug" se encargará de incluirlas y hacer que el discriminador no pueda aprender a diferenciarlas. Esto conlleva finalmente a una generación de imágenes que no incluyen transformaciones.

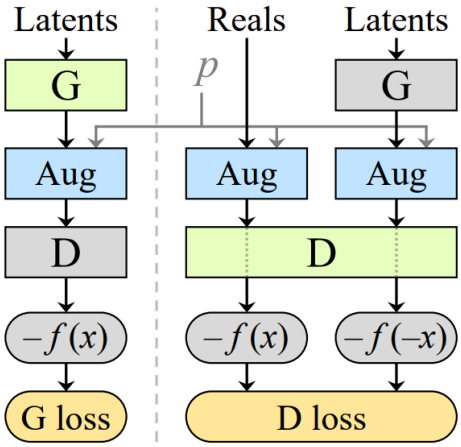


Figura 2.10: Estructura de aumento de datos adaptativo en GANs para evitar sobreajuste. El flujo de la izquierda corresponde a la pérdida del generador mientras que el flujo de la derecha es cómo se calcula la del discriminador. AUG es una función que según el valor de p, aplicará transformaciones a las imágenes recibidas y las devolverá. Fuente: [Tero Karras et al., 2020]

El mismo estudio profundiza en la elección de un valor óptimo de p que pueda ser empleado en la mayoría de casos con buenos resultados, indicando que cuando p se mantiene

por debajo del 0.8, es poco probable que las filtraciones se produzcan en la práctica. En este contexto, define la técnica del aumento adaptativo discriminante, que consiste en un valor variable de p durante el entrenamiento. El procedimiento es el siguiente: este se inicializa en 0 y cada 4 conjuntos de imágenes (normalmente cada conjunto posee 64 muestras) se comprueba el valor de dos heurísticas de sobreentrenamiento r_v y r_t y se ajusta según lo obtenido. Si los valores indican un sobreentrenamiento débil, se decrementa p y si los valores indican un sobreentrenamiento acentuado, se incrementa.

$$r_v = \frac{E[D_{train}] - E[D_{validation}]}{E[D_{train}] - E[D_{generated}]} \qquad r_t = E[sign(D_{train}))]$$

Los valores D_{train}, $D_{validation}$ y $D_{generated}$ corresponden a la salida del discriminador para el conjunto de entrenamiento, de validación y de las imágenes sintéticas, E corresponde a la media de esos valores durante los 4 conjuntos de muestras indicados anteriormente y *sign* es una función que modifica el signo del valor actual. El índice r_v expresa la salida obtenida para el conjunto de validación en relación con el conjunto de entrenamiento y generado, mientras que r_t estima la proporción del conjunto de entrenamiento que obtiene valores positivos del discriminador.

Antes de abordar los resultados obtenidos, indicar que el estudio, tras realizar todos los experimentos, llega a la conclusión de que a la hora de entrenar un GAN con un conjunto de datos pequeño, es conveniente emplear el índice KID en lugar del FID, debido a que este último se ve perjudicado por un sesgo inherente cuando el conjunto de datos es demasiado reducido, mientras que KID está diseñado para evitarlo.

Las conclusiones de este estudio evidencian que esta técnica estabiliza el entrenamiento de los GANs y mejora enormemente la calidad de los resultados cuando el conjunto de datos es limitado. Esta investigación es muy relevante en el desarrollo de este trabajo ya que sirvió como guía a la hora de comprender el fenómeno del sobreentrenamiento, las métricas de evaluación de los GANs e incluso la técnica de aumento de datos propuesta, que se abordará en el siguiente capítulo.

Capítulo 3

Métodos

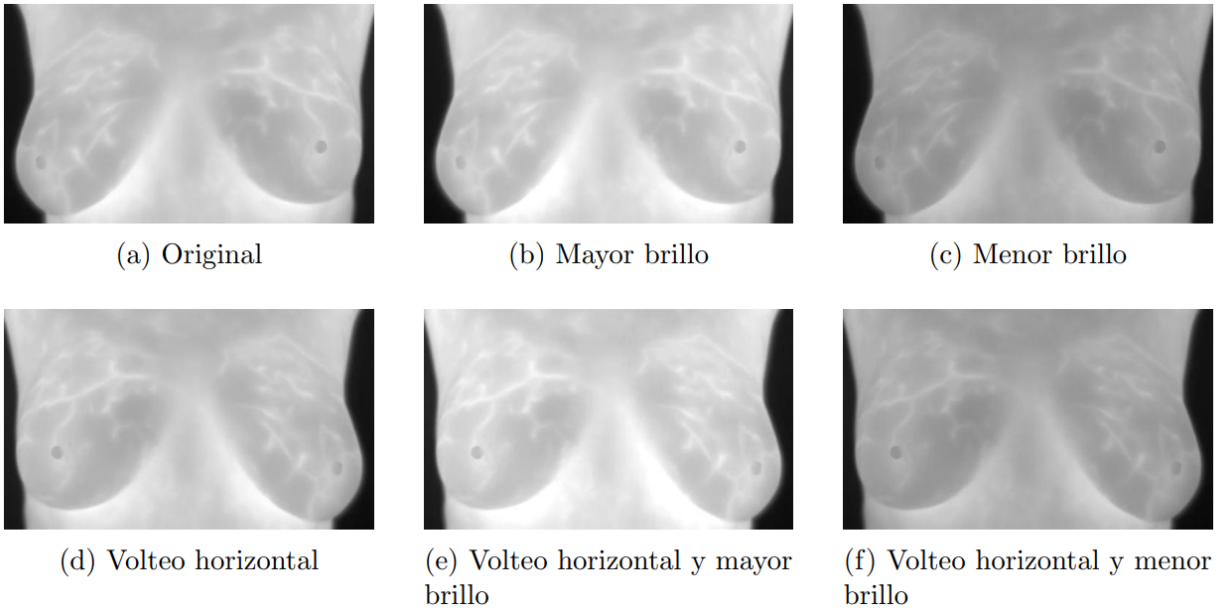
En el presente capítulo se describen los métodos e implementaciones llevadas a cabo durante el desarrollo de este proyecto. Por tanto, se detalla el preprocesamiento del conjunto de datos, la selección del modelo GAN, el entrenamiento del mismo, las métricas de evaluación empleadas, el procedimiento de generación de imágenes sintéticas para el aumento de datos, la implementación de la técnica que evita filtraciones en las transformaciones, la afinación de hiperparámetros, la validación cruzada y finalmente el proceso completo donde se ejecuta esta validación cruzada durante 10 iteraciones.

3.1. Conjunto de datos

En este proyecto se emplea la Base de Datos para la Investigación Mastológica con Imágenes Infrarrojas [Lincoln da Silva et al., 2014], la cuál contiene datos clínicos de 280 pacientes voluntarias. Este conjunto de datos consiste en distintas fotografías desde varios ángulos de las mamas, en escala de grises a un tamaño de 640x480 píxeles. Tras descartar imágenes no útiles (p. ej., masectomía o ropa) y seleccionar las fotografías realizadas de frente, se obtienen 260 muestras distintas de las cuáles 166 son sanas y 94 enfermas [Aguilar, 2022]. En el trabajo previo cada imagen fue recortada de manera manual para centrar la región de interés en las mamas y eliminar información irrelevante. Las imágenes se reescalan a resolución 56x56 antes de alimentarlas al modelo predictivo, ya que es una resolución muy utilizada en tareas de aprendizaje automático con imágenes. Para profundizar más en el procedimiento llevado a cabo para la obtención de este conjunto de datos, se remite al trabajo [Aguilar, 2022].

Dado el reducido tamaño del conjunto de datos (260), en el proyecto previo se aplicaron técnicas de aumento de datos para mejorar el rendimiento del modelo. El proceso que se llevó a cabo fue generar, por cada imagen del conjunto, 10 imágenes aumentadas aplicando un 50 % de probabilidad de volteo horizontal y aleatoriamente una pequeña alteración del brillo [Aguilar, 2022] (véase fig. 3.1). El trabajo anterior no aplicaba esta técnica al conjunto

de datos completo, sino que particionaba los datos entre entrenamiento y prueba y sólo la aplicaba al primero. Con esto se pretendía que todos los modelos fueran evaluados bajo las mismas particiones. En el proyecto actual, para evitar sesgos y aprovechar al máximo la cantidad de datos disponibles, se han aplicado estas técnicas de aumento de datos al conjunto completo, de forma que cuando se particione entre entrenamiento y prueba, se utilizará un método que evitará el filtrado de las imágenes aumentadas entre conjuntos, lo que podría ocasionar de nuevo otro sesgo al mezclar imágenes con un mismo origen en ambos. Gracias a este procedimiento, el conjunto de datos sin particionar consta de 3113 muestras. No obstante, se debe considerar que tras la partición habrá una cierta pérdida de imágenes ya que las imágenes reales que entren en el conjunto de prueba deberán eliminar sus imágenes aumentadas eliminadas de todos los conjuntos, al igual que en prueba se eliminarán las imágenes aumentadas para obtener resultados más precisos e imparciales.



(a) Original (b) Mayor brillo (c) Menor brillo

(d) Volteo horizontal (e) Volteo horizontal y mayor brillo (f) Volteo horizontal y menor brillo

Figura 3.1: Ejemplo del aumento de datos aplicado al conjunto de datos. Fuente: [Aguilar, 2022]

3.2. Modelo GAN seleccionado

Diversos tipos de GANs fueron considerados para el desarrollo de este proyecto, entre los que destacan el sGAN (GAN semisupervisado) y el cGAN (GAN condicional). En una primera instancia, se seleccionó *sGAN* para generar las imágenes sintéticas. Este modelo posee la particularidad de recibir tanto imágenes etiquetadas como sin etiquetar, por lo que el discriminador no solo indica si la imagen es generada o no, sino también la clase. Para llevar esto a cabo, el discriminador debe poder predecir una clase adicional, etiquetada como "desconocida". La implementación se basa los conceptos descritos en [Brownlee, 2020], donde

en uno de los apartados se menciona que es posible modelar un *sGAN* añadiendo 2 salidas al discriminador:

- Salida no supervisada: indica si la imagen es sintética o no, 2 posibles valores: 0 o 1.
- Salida supervisada: indica a qué clase corresponde la imagen o si es una imagen no etiquetada, NUMERO_CLASES + 1 posibles valores.

Este diseño de la red tiene una peculiaridad y es que si la salida no supervisada indica que la imagen es generada (1), entonces la otra salida (supervisada) no será relevante y se podrá omitir la predicción. En la fig. 3.2 se puede observar un esquema del sGAN utilizado, mostrando las características mencionadas anteriormente.

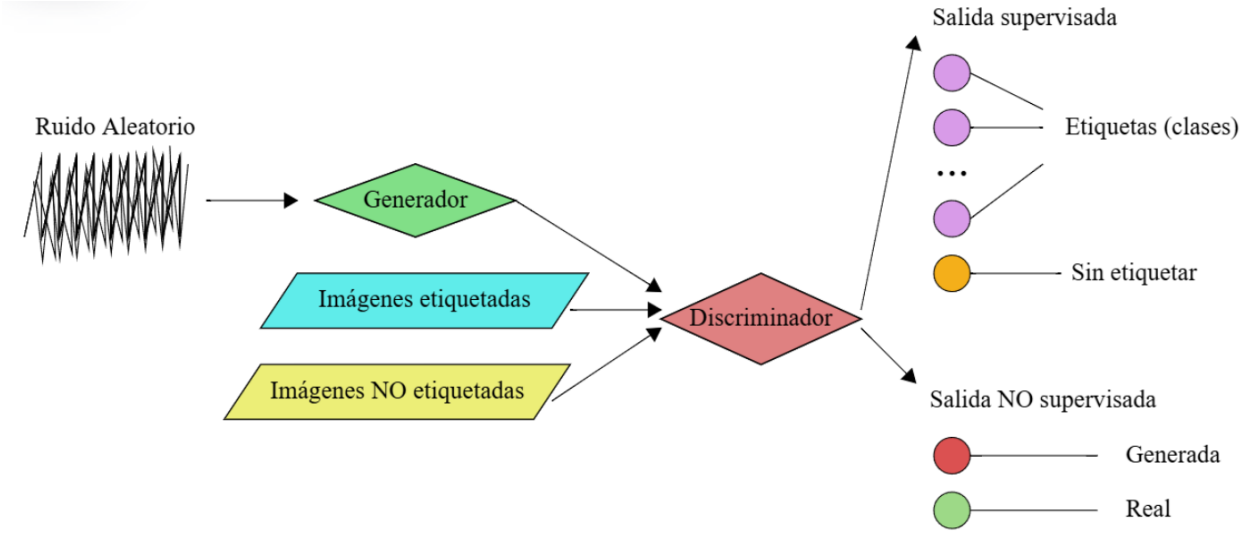


Figura 3.2: Esquema de la implementación del sGAN inicialmente utilizado.

Esta arquitectura supera el rendimiento de otros modelos GANs tradicionales ya que al incorporar la salida supervisada, el discriminador posee una mayor eficacia en la detección de muestras sintéticas. Esto se debe a que no solo aprende a reconocer las clases sino también a diferenciar entre imágenes reales y sintéticas, proporcionando una mayor capacidad de detección y causando a su vez que el generador reproduzca imágenes más realistas y coherentes. Sin embargo, tras varias pruebas y afinaciones, se comprobó que el modelo no devuelve resultados prometedores incluso con un número de iteraciones alto (10.000 epochs - 24 horas), como se puede ver en la fig. 3.3 a. Este modelo fue seleccionado inicialmente con la idea de aprovechar algunas de las muestras del conjunto de datos original no etiquetadas. No obstante, la cantidad es ínfima (alrededor de 5) y probablemente no posea un impacto significativo en los resultados finales.

Tras esto, se decide emplear *StyleGAN* por el potencial y las ventajas que ofrece, las cuáles están recogidas en el capítulo anterior. Debido a la infraestructura del mismo, las

imágenes deben ir duplicando su resolución en cada ronda hasta finalizar con el tamaño final, 56x56 píxeles. Por ello, se diseña un entrenamiento en 4 pasos, de forma que el modelo entrena con las muestras en resoluciones de 7x7, 14x14, 28x28 y 56x56 píxeles.

A pesar de que *StyleGAN* obtuvo un mejor rendimiento que *sGAN*, los resultados no reflejaban el potencial de este modelo generativo. Por esta razón, se utiliza una técnica adicional al entrenamiento que permite mejorar el rendimiento aún más. Con el objetivo de aumentar el número de pasos del entrenamiento y permitir que el modelo generativo trabaje con imágenes de mayor calidad, el conjunto de datos se redimensiona a 128x128 píxeles, de forma que los pasos de entrenamiento se componen de 4x4, 8x8, 16x16, 32x32, 64x64 y 128x128, aumentando el total de 4 a 6. Este procedimiento mejoró enormemente la calidad de las imágenes y la eficiencia del entrenamiento, ya que como se puede observar en la fig. 3.3 b, las imágenes tienen un mayor detalle y una gran nitidez con apenas 2 horas y media (50 epochs) de entrenamiento. Debido a esto, el *StyleGAN* actualmente genera imágenes de 128x128 píxeles, por lo que, una vez entrenado, se redimensionan todas las imágenes a 56x56 para alimentarlas al modelo predictivo, ya que este recibe las muestras de entrada en esa resolución. En la fig. 3.4 se muestra un esquema del proceso.

Tal y como se mencionó en el capítulo anterior, el modelo *StyleGAN* cuenta con dos versiones más avanzadas: *StyleGAN2* y *StyleGAN3*. No obstante, para el desarrollo de este proyecto se opta por emplear el modelo base, ya que la arquitectura del modelo es compleja, lo que hace recomendable adquirir un conocimiento sólido del modelo antes de abordar versiones más actualizadas, que incorporan un mayor número de características. Cabe señalar que la implementación de este modelo se basó en el repositorio de código de [Elilah, 2023] en *PyTorch*, ya que recoge una implementación desde cero.

3.3. Entrenamiento del GAN

Como se comentó en el capítulo introductorio, uno de los objetivos de este trabajo es definir un sistema de entrenamiento, recopilación de datos y evaluación del sistema generativo. De esta forma, se podrán analizar los resultados obtenidos para dar una conclusión final. En cada entrenamiento se decidieron conservar los siguientes datos:

- Funciones de pérdidas tanto de discriminador como de generador reflejadas en gráficas.
- Puntuación *KID* y *FID* reflejadas en gráficas.
- Tiempo de ejecución, iteraciones, últimos resultados obtenidos en KID, FID y funciones de pérdida y datos completos de KID y FID. Estos datos irán recogidos en un fichero txt.

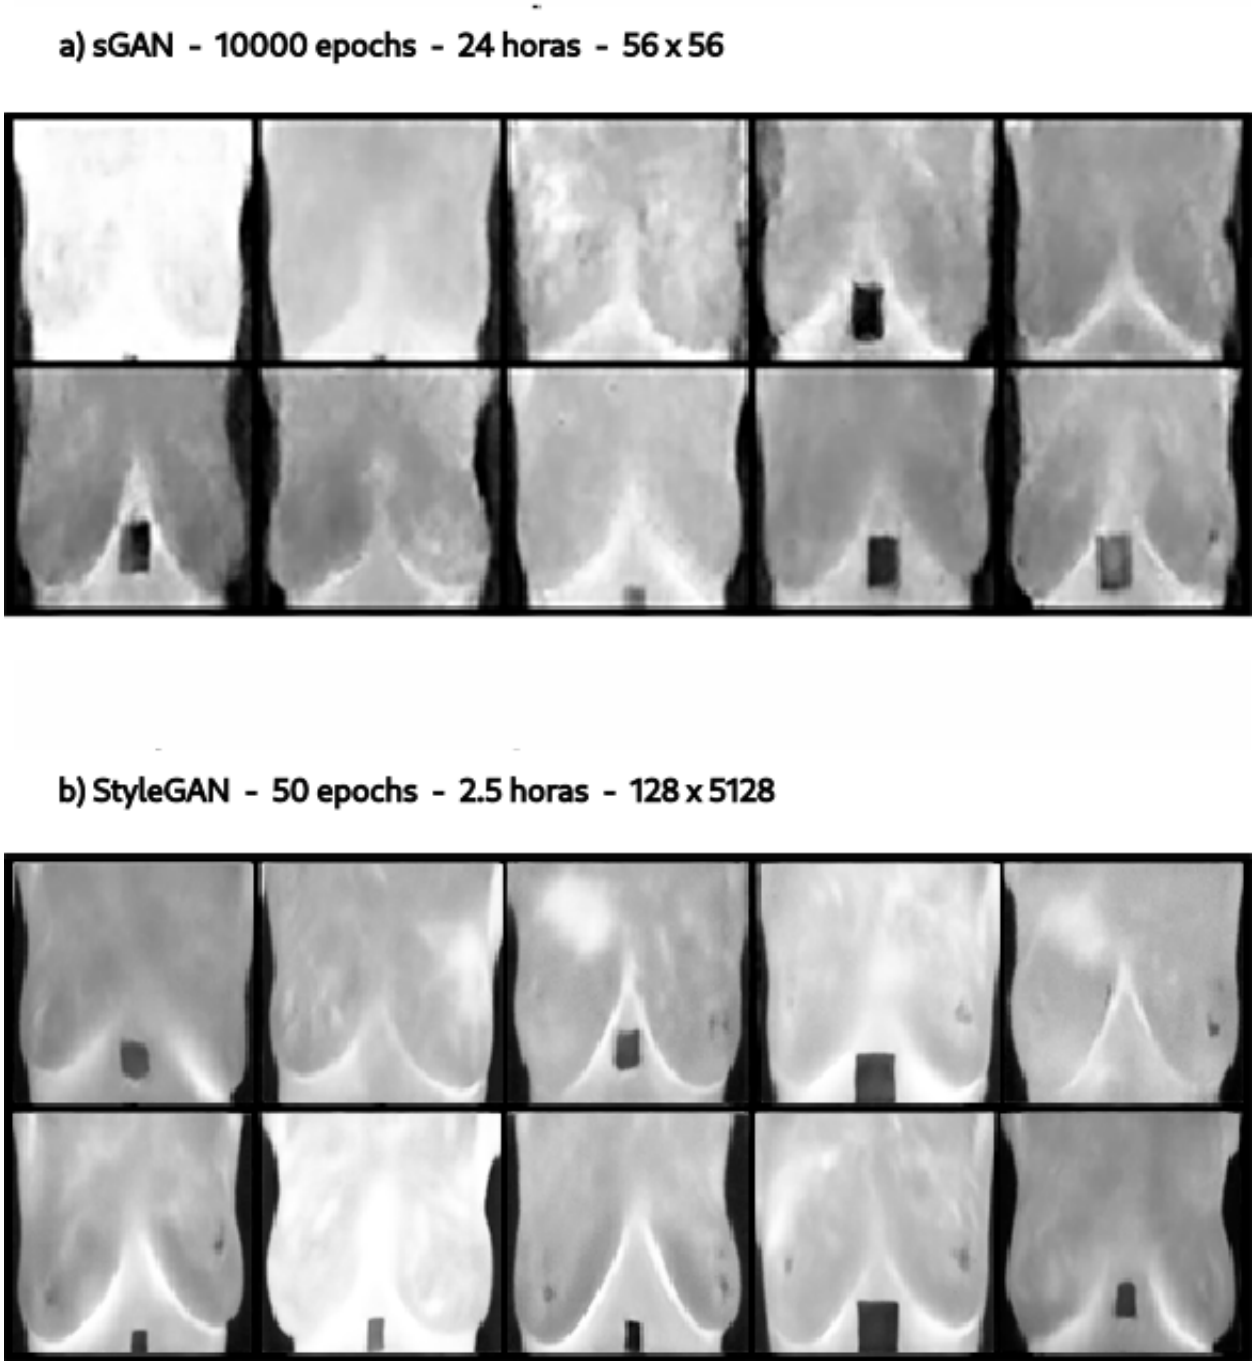


Figura 3.3: Imágenes generadas por los distintos modelos GANs. a) Imágenes de 56x56 píxeles generadas por el sGAN durante 24 horas de entrenamiento (10.000 epochs) sin la técnica de redimensionado. b) Imágenes de 128x128 píxeles generadas por el StyleGAN en 2.5 horas (50 epochs) redimensionando las imágenes alimentadas a 128x128.

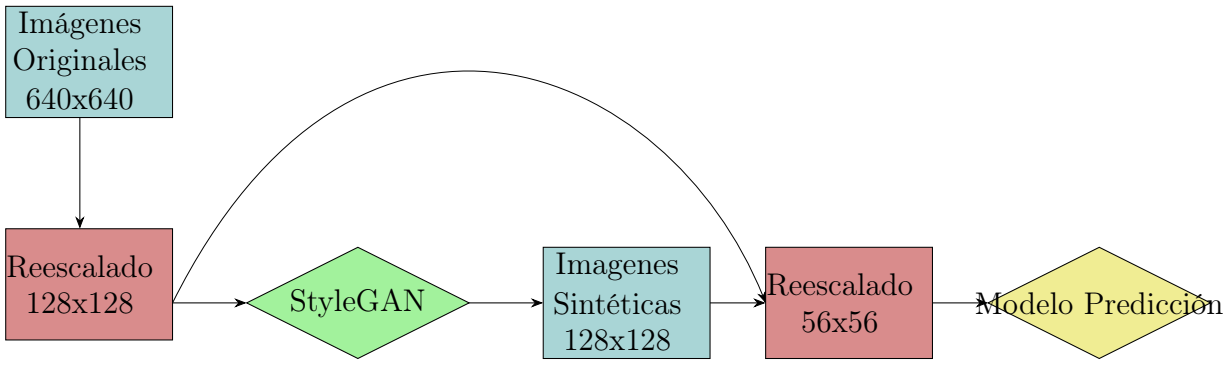


Figura 3.4: Esquema del proceso de redimensionado de las imágenes para mejorar el entrenamiento del *StyleGAN*.

- Imágenes del generador durante la ejecución del modelo. Cada cierto número de iteraciones, se almacenarán N imágenes del generador en la carpeta indicada para comprobar el progreso del entrenamiento.

En la fig. 3.5 se pueden observar algunos ejemplos de la información almacenada durante la ejecución del modelo. Los parámetros que definen cómo se almacenan las métricas de evaluación, y muchas otras variables, se han implementado de manera óptima para ser modificadas a través de un fichero de constantes (*constants.py*) con la finalidad de realizar distintos tipos de ejecuciones. Por ejemplo, se puede seleccionar la frecuencia con la que se almacenan la pérdida y el *KID Score* (esto cambiará la gráfica a su vez), el número de muestras que se almacenan durante la ejecución, las iteraciones o el ratio de aprendizaje de Generador y Discriminador, entre otra serie de parámetros.

El entrenamiento se lleva a cabo dividiendo el conjunto de datos entre entrenamiento, validación (se utiliza para el *KID Score y FID Score*) y prueba, aunque este último no se utiliza en esta fase del modelo generativo, sino que se reserva para el modelo predictivo. Como se mencionó anteriormente, para evitar un sesgo a la hora de particionar el conjunto de datos, se lleva a cabo un procedimiento que asegura que los conjuntos de validación y prueba no poseen imágenes aumentadas de los pacientes del conjunto de entrenamiento. Asimismo, se asegura que el conjunto de entrenamiento no posea imágenes aumentadas de los pacientes de los otros dos conjuntos, ya que supondría que los modelos están entrenando con las mismas imágenes (o muy similares) con las que se realiza la evaluación. Dado que el objetivo consiste en generar imágenes de gran calidad tanto sanas como enfermas, se llega a la conclusión de que la manera más eficiente, utilizando *StyleGAN*, es crear un modelo para cada tipo. De esta manera, cada uno recibe únicamente imágenes enfermas o sanas, lo que aumenta la robustez del aprendizaje, reproduciendo imágenes más realistas y verosímiles. Por tanto, los datos del conjunto de entrenamiento se dividen a su vez en dos particiones:

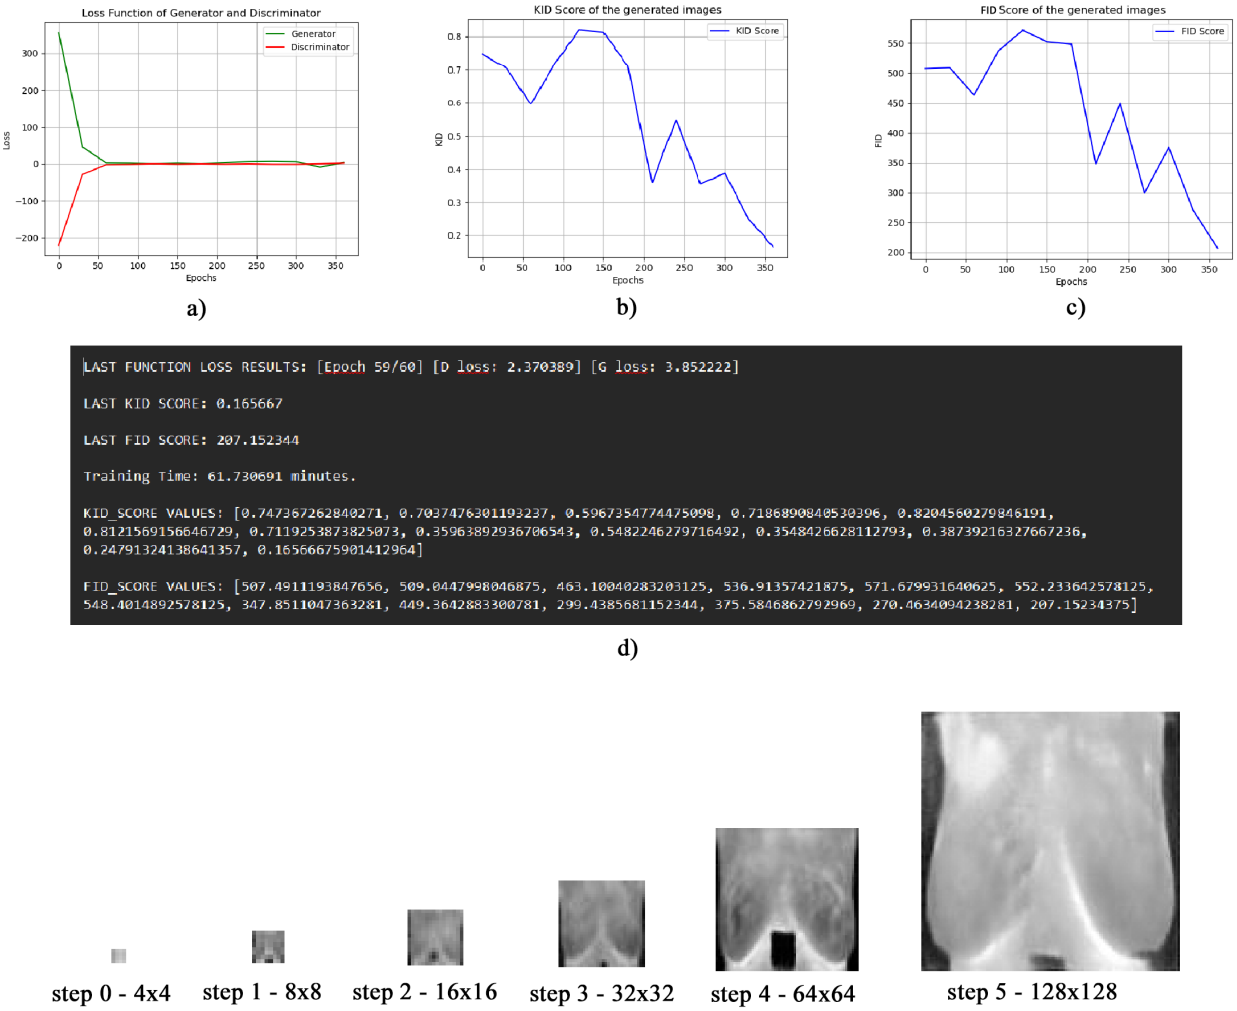


Figura 3.5: Datos recogidos durante el entrenamiento del StyleGAN. a) Funciones de pérdida de ambos modelos: generador y discriminador. b) KID Score. c) FID Score. d) Archivo de registro del proceso de entrenamiento. e) Muestras de las imágenes generadas en cada *step* (paso) del entrenamiento.

enfermas y sanas, y cada una es proporcionada al modelo *StyleGAN* correspondiente. Una vez entrenados los modelos y generadas las imágenes para el aumento de datos, estas se integran con el conjunto de datos base para proporcionarlo al modelo predictivo.

3.4. Métricas de evaluación

Tal y como se comentó en el capítulo anterior, las métricas empleadas para evaluar el rendimiento del modelo generativo serán las puntuaciones *KID y FID*, siendo la puntuación *KID* la principal gracias a la mitigación de sesgos cuando se emplea en conjuntos de datos pequeños. Para recoger datos en el entrenamiento, cada N iteraciones se almacenará una medición tanto de la puntuación *KID* como de *FID* para realizar las gráficas y para devolver los resultados en el fichero *.txt*.

El cálculo de estas métricas presenta ciertas particularidades, ya que ambas requieren una gran cantidad de imágenes sintéticas y una porción de imágenes reales. En el estudio original del *FID* [Martin Heusel et al., 2017] se recomienda que la cantidad de imágenes sintéticas a proporcionar a las funciones sea de alrededor de 10.000. No obstante, debido a que los tiempos de ejecución son muy largos y a que el conjunto de datos es reducido, se concluye que reproducir 10.000 imágenes sintéticas es innecesario y contraproducente. Por tanto, cada vez que se calculen ambas funciones, se utilizarán 1.000 imágenes en lugar de las 10.000. Con esta decisión se está sacrificando algo de precisión en el valor obtenido a cambio una reducción considerable del tiempo de entrenamiento para el modelo generativo. Se ha colocado en el fichero de constantes una variable que permite modificar esta cantidad, de forma que sea posible obtener más precisión en estas métricas cuando se realicen otro tipo de pruebas.

Tal y como se indica en sus respectivos estudios, tanto *FID* [Martin Heusel et al., 2017] como *KID* [Mikołaj Bińkowski et al., 2018] requieren de un conjunto de validación para poder computar sus valores. Esto se debe a que el generador aprende a reproducir imágenes similares a las del conjunto de entrenamiento, por lo que computar KID/FID mediante las imágenes sintéticas junto con las del conjunto de entrenamiento proporciona un valor sesgado, ya que estas serán inevitablemente similares entre ellas y por tanto el valor de las métricas será bajo (cuanto menor, imágenes más verosímiles). Para evitar esto, se utiliza un conjunto auxiliar de validación que permite conocer si el modelo está generalizando correctamente y si reproduce imágenes similares a otras con las que no ha entrenado anteriormente. Esto permitirá seleccionar modelos más robustos y con menor sobreajuste.

Para llevar a cabo todo lo explicado anteriormente, se ha creado una función llamada *compute_KID_FID_Score* que recibe el generador, el conjunto de validación y el número de imágenes a generar. Esta función se encarga de:

1. Detener el entrenamiento del generador. Para generar imágenes con el aprendizaje obtenido hasta ahora hay que poner el modelo en modo de evaluación (*model.eval()*).

2. Generar el número de imágenes indicadas. Las imágenes generadas irán en lotes de 64 hasta igualar o superar el número indicado (variable del fichero de constantes).

3. Alimentar a las funciones tanto imágenes sintéticas como reales. Se añaden las N imágenes sintéticas y el conjunto de validación (imágenes reales).

4. Se obtiene el valor de los índices.

5. Se reanuda el entrenamiento del generador y se devuelven las puntuaciones obtenidas.

Para calcular *FID y KID* se utilizarán las funciones *KernelInceptionDistance* y *FrechetInceptionDistance* de la librería *torchmetrics.image*.

3.5. Aumento de datos

Una vez definido el entrenamiento del GAN y las métricas de evaluación, se procede a generar las imágenes que van a ser utilizadas en el aumento de datos. Tras entrenar el sistema generativo, se observó que en ocasiones se reproducen imágenes poco similares al conjunto de datos real. Este comportamiento es común en los GANs cuando se trabaja con un conjunto de datos pequeño, ya que el modelo no logra aprender de manera robusta las características esenciales de las muestras. Para la tarea que se quiere llevar a cabo es importante evitar estas imágenes, ya que aportarán poca información al modelo predictivo. Por esta razón, se ha decidido implementar un proceso de filtrado por lotes para conservar únicamente aquellas muestras con una mayor similitud.

Para llevar a cabo este filtrado, es necesario emplear un índice que permita conocer la verosimilitud o realismo de cada lote de imágenes. Se utiliza la puntuación *KID* al posee una gran resistencia a sesgos en comparación con la puntuación *FID*. Tanto *KID* como *FID* evalúan las imágenes por lotes en lugar de individualmente, esta es la razón por la que el filtrado se lleva a cabo en conjunto y no por separado. Como se comentó anteriormente, estos índices reciben un conjunto de imágenes tanto sintéticas como reales para computar una función de distancia entre ambos, utilizando la función de activación de la última capa de la red neuronal *Inception v3*.

Para que un lote de imágenes sea incluido en el aumento de datos, se establece un umbral de calidad basado en el valor de la puntuación *KID*. Un lote será aceptado cuando su puntuación *KID* sea inferior o igual al umbral; en caso contrario, se descarta el lote y se vuelve a generar. Este umbral forma parte también de las constantes del fichero *constants.py*, lo que permite modificarlo fácilmente para llevar a cabo otras ejecuciones. Para evitar iteraciones

infinitas donde el modelo no sea capaz de cumplir con el criterio de calidad, se establece una condición de parada: cada N ejecuciones sin superar el umbral (por defecto 3), se almacenará el lote actual independientemente de su valor de *KID Score*. Esto permite obtener las imágenes sintéticas en menor tiempo de ejecución sacrificando algo de calidad de las mismas.

Para implementar este proceso, se diseña la función *evaluate_images*, la cuál recibe un lote de 64 imágenes junto con el conjunto de validación. Los conjuntos son alimentados a la función *KID* y esta calcula el valor obtenido para ese lote de imágenes. Posteriormente, se desarrolla la función principal *data_augmentation*, la cuál recibe el generador, el conjunto de validación, el número de imágenes a generar y si las imágenes a generar son enfermas o sanas. Los pasos que sigue son los siguientes:

1. Generar un lote de 64 imágenes.
2. Llamar a la función *evaluate_images* y obtener el valor de *KID* para ese lote.
3. Si el valor de KID es menor o igual que el límite o se ha superado el número de reintentos, se almacena ese lote. En caso contrario, se vuelve a generar uno (paso 1).
4. Con las imágenes sintéticas se construye un tipo de datos *CancerDetectionDataset*, el cuál es utilizado como entrada al modelo predictivo. Esta variable consta de los siguientes parámetros: ruta, etiqueta (sana o enferma) y la imagen en sí. La ruta utilizada para almacenar estas imágenes será *DATA_AUGMENTATION_SICK* o *DATA_AUGMENTATION_HEALTHY* dependiendo de si se están generando muestras sanas o enfermas. Esta es la razón por la que la función *data_augmentation* tiene un valor de entrada que indica si se generan sanas o enfermas.
5. Se devuelve el conjunto de datos de imágenes sintéticas (tipo de dato *CancerDetectionDataset*).

3.6. Aumento de datos sin filtrado de transformaciones

Como se discutió previamente en la sección 2.2.2, el trabajo [Tero Karras et al., 2020] se centa en el entrenamiento de los GANs cuando se tiene un conjunto de datos limitado. Este recoge ciertas técnicas para reducir la inestabilidad del entrenamiento de los GANs, recomendando procedimientos para evitar que las transformaciones del aumento de datos (volteos, cambios de brillo, étc...) se filtren a las imágenes generadas por GAN. Para ello, se utiliza la infraestructura mostrada en la fig. 2.10.

Una vez consolidada una metodología robusta para el entrenamiento y generación de imágenes con fines de aumento de datos, se planteó la hipótesis de que la infraestructura descrita anteriormente podría contribuir a mejorar la estabilidad de los GANs, reduciendo

así los fallos de convergencia. Con este objetivo y utilizando la fig. 2.10 como referencia, se aplicaron transformaciones con una posibilidad de *p=0.8* a todas las imágenes que el discriminador recibía. La elección del valor de p se basa en el proyecto descrito en [Tero Karras et al., 2020], donde se observaba que 0.8 posee una gran efectividad en entornos con datos limitados. Las imágenes reales ya incluyen las transformaciones descritas en la sección 3.1, por lo que se implementó una función llamada *not_leaking_data_augmentations* para aplicar las mismas transformaciones a las imágenes sintéticas (brillo y volteo horizontal). Cabe destacar que la función no altera ni el generador ni a las muestras sintéticas, sino que actúa como una especie de filtro que simula un aumento de datos para que el discriminador las perciba de esta forma. La función *not_leaking_data_augmentations* recibe un lote de imágenes y el valor de p y devuelve el mismo lote ya transformado.

Esta función fue integrada en las secciones correspondientes del entrenamiento con el objetivo de evaluar el impacto de la técnica descrita. En cuanto a la puntuación *KID*, se puede observar en la fig. 3.6 que en las últimas etapas del entrenamiento se alcanzan valores de alrededor del 0.3, los cuáles empeoran los resultados obtenidos hasta ese momento que eran de alrededor del 0.2. Este declive de los valores de *KID Score* se traduce en peores imágenes sintéticas, como se puede observar en la fig. 3.7, donde las imágenes son mucho menos nítidas y borrosas si se comparan con las de la fig. 3.3 b.

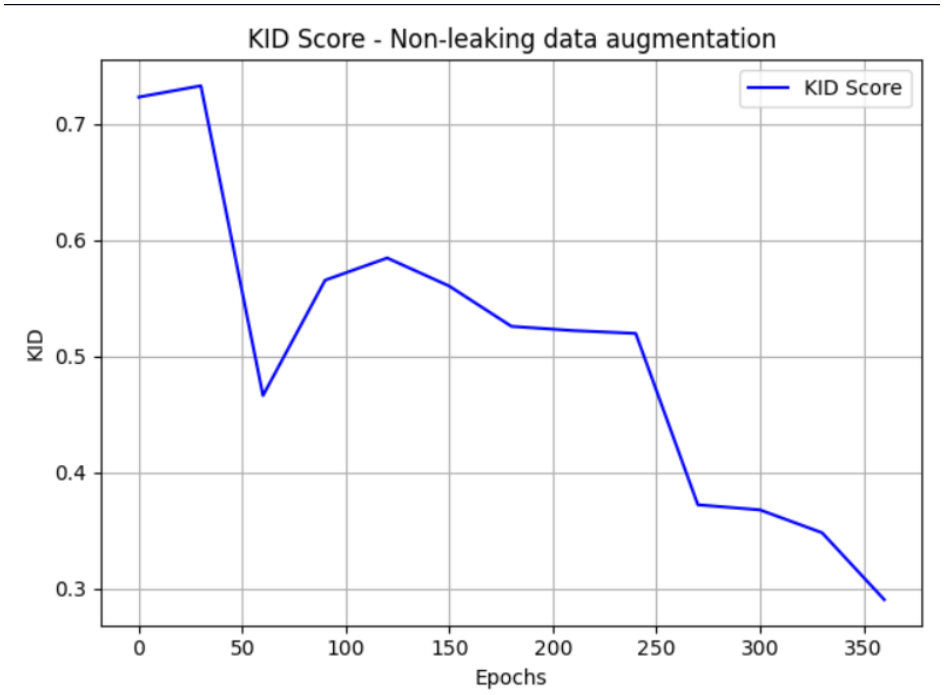


Figura 3.6: *KID Score* de las imágenes generadas mediante la técnica de no filtrado de transformaciones.

Tras implementar la técnica descrita, se comprobó que no aporta mejoras a la estabilidad



Figura 3.7: Muestras generadas por el GAN sin filtrado de aumento de datos.

de los GANs y que empeora los resultados obtenidos hasta ahora, por lo que se tomó la decisión de prescindir de ella. La razón por la que esta técnica no demuestra una efectividad en este proyecto es por el tamaño extremadamente reducido del conjunto de datos. En el estudio [Tero Karras et al., 2020] se menciona que, a pesar de que la técnica arroja buenos resultados para conjuntos de datos pequeños, si este es demasiado limitado, la eficacia se verá reducida. De hecho, todos los ejemplos mostrados son con conjuntos de alrededor de 2000 muestras, mientras que para este proyecto se poseen 260.

3.7. Afinación de hiperparámetros

Como se describió en la sección 3.3, el proceso de aumento de datos se lleva a cabo implementando dos modelos *StyleGAN*, uno que entrena con muestras sanas y otro con enfermas. Una vez diseñado el flujo de entrenamiento y aumento de datos, se realizaron las primeras pruebas particionando los datos hacia cada modelo. Los primeros resultados demostraron un rendimiento deficiente por parte de ambos. Esta degradación se atribuye principalmente a la reducción del conjunto de datos de entrenamiento al dividirlo entre imágenes sanas y enfermas. Por otro lado, en la mayoría de ocasiones, los modelos llegaban a un fallo de convergencia de manera muy rápida, alcanzando un punto de no retorno donde se generaban imágenes completamente negras.

Con el objetivo de mitigar los problemas observados, se procede a realizar una afinación de hiperparámetros a cada modelo. Esta estrategia busca que cada modelo se adapte a su conjunto de datos de manera eficiente, generando mejores imágenes y mitigando la aparición de un fallo de convergencia. Se tomó la decisión de realizar una afinación de tipo de búsqueda en cuadrícula, ya que permite localizar configuraciones subóptimas en un tiempo razonable. Para ello, se tienen en cuenta los siguientes parámetros junto a sus posibles valores:

- Ratio de aprendizaje (*Learning Rate*) del Generador. Se considera 0.00001, 0.0002 y 0.0001.
- Ratio de aprendizaje (*Learning Rate*) del Discriminador (Crítico). Se considera 0.001, 0.0002 y 0.0001

- B_1, parámetro utilizado en el cálculo del optimizador Adam, es decir, de la función del gradiente de los modelos. Se considera 0.00001 y 0.5.
- B_2, otro parámetro utilizado dentro del optimizador Adam. Se considera 0.9 y 0.999.

Se seleccionan estos valores de manera empírica ya que durante las primeras ejecuciones de los modelos, estas configuraciones conllevaban un gran rendimiento del modelo GAN.

Para llevar a cabo la afinación, se diseña un programa que almacena todos estos posibles valores y en cada iteración ejecuta una configuración distinta hasta llevar a cabo todas las combinaciones posibles. Se estableció un número de iteraciones fijo de 60, ya que es un valor que no alarga demasiado el proceso de entrenamiento pero devuelve buenos resultados. En cada iteración, se entrena el modelo con el mismo subconjunto de datos para evitar sesgos. Asimismo, es importante mencionar que en cada una de las dos afinaciones se utiliza un subconjunto de imágenes enfermas o sanas, dependiendo del modelo. En cada iteración, se particiona el conjunto entre entrenamiento y validación y se entrena el modelo. Cuando finaliza el entrenamiento, se utiliza la función *compute_KID_FID_Score* mencionada en la sección 3.4 para evaluar la puntuación *KID* y comprobar el rendimiento del modelo con la configuración actual. Dado que es necesario obtener una mayor precisión en esta métrica para conocer qué combinación provoca un mejor rendimiento, en este caso se generan 10.000 imágenes para calcular la puntuación *KID*.

En todo momento se almacenan e imprimen los valores obtenidos de *KID* y *FID* y finalmente se muestra la configuración con el mejor rendimiento junto con el resto de valores, especificando *KID Score*, *FID Score*, los parámetros de esa iteración y el tiempo total de ejecución. Un ejemplo de las ejecuciones es el siguiente:

```
The best result is
LEARNING RATE: 0.001 - LEARNING RATE GEN: 0.0001 - B_1: 1e-05 - B_2: 0.9 -
EPOCHS: 60 with KID Score 0.10774284601211548
and FID Score 178.86241149902344.

Hyperparameter Tuning Time: 2710.534168 minutes.

And all the results are:
{'KID Score': 0.18610787391662598, 'FID Score': 223.8437957763672,
'LR DIS': 0.001, 'LR GEN': 1e-05, 'B_UNO': 1e-05, 'B_DOS': 0.9,
'EPOCHS': 60}

{'KID Score': 0.34287554025650024, 'FID Score': 334.8471984863281,
'LR DIS': 0.001, 'LR GEN': 1e-05, 'B_UNO': 1e-05, 'B_DOS': 0.999,
```

```
'EPOCHS': 60}
.....
```

Finalmente, tras ejecutar cada afinación, los resultados y las mejores configuraciones obtenidas son las siguientes:

Afinación	Tiempo (hrs)	KID	FID	LR_GEN	LR_DIS	B_1	B_2
Sanas	45,16	0.107	178.8	0.0001	0.001	1e-05	0.9
Enfermas	33,06	0.128	212.9	0.0002	0.001	0.5	0.9

Tabla 3.1: Resultados obtenidos de las afinaciones de hiperparámetros a los dos modelos: entrenado con subconjunto de muestras sanas y con enfermas.

Las mejores configuraciones de hiperparámetros se almacenan como listas en una variable del fichero de constantes para que, durante las ejecuciones finales de este proyecto, se utilice la configuración adecuada dependiendo del modelo que se esté entrenando en ese momento. Se puede observar que el modelo con muestras sanas tiene mayor tiempo de entrenamiento y mejores resultados de *KID y FID Score*. Esto es debido a que el conjunto de datos tiene mayor número de imágenes sanas que enfermas como se comentó en la sección 3.1. A pesar de ello, ambos obtuvieron unos resultados muy buenos y las imágenes comenzaron a tener una mayor calidad y a producirse una menor cantidad de fallos de convergencia.

3.8. Validación cruzada

Una vez implementado el flujo de entrenamiento de los *GANs*, realizada la afinación de hiperparámetros y construido el método para la generación de imágenes, el siguiente paso consiste en evaluar el impacto de las imágenes sintéticas sobre el rendimiento del modelo predictivo. En el proyecto [Aguilar, 2022] se proponen 4 tipos de modelos predictivos, por lo que se debe tomar una decisión sobre qué modelo será empleado en este estudio:

- Modelo simple basado en una red neuronal
- Modelo con mecanismo de auto-atención
- Modelo con mecanismo de atención suave
- Modelo con mecanismo de atención dura

Como se puede observar en la fig. 3.8, el modelo con el mejor rendimiento fue el que emplea mecanismos de atención dura, por lo que se selecciona e implementa en este proyecto para estudiar el potencial del aumento de datos mediante GANs.

En el proyecto [Aguilar, 2022], la evaluación de los modelos se realiza en dos fases: primero mediante validación cruzada sobre los conjuntos de entrenamiento y validación y

a continuación una evaluación con un conjunto de prueba fijo reservado para esta ejecución. Este enfoque no es demasiado robusto a la hora de evaluar los modelos ya que usar un conjunto de prueba estático conlleva sesgos en los resultados. Para mejorar la evaluación del modelo de predicción y obtener resultados más fiables, como se explicó en la sección 3.1, se unifica este conjunto de prueba al resto de datos aplicando las mismas técnicas de aumento de datos y se mantiene únicamente la evaluación mediante validación cruzada, ya que proporciona mayor fiabilidad a la hora de evaluar el rendimiento de los modelos. Por tanto, para evaluar el modelo de predicción de atención dura, se empleará la validación cruzada con 5 pliegues y utilizando el conjunto de datos de 3113 muestras.

Modelos	**Exactitud (%)**	**Especificidad (%)**	**Precisión (%)**	**Exhaustividad (%)**	**Puntuación F1 (%)**
CNN	87.11 %	89.92 %	86.02 %	83.33 %	84.66 %
CNN + Auto-atención	89.78 %	92.25 %	89.25 %	86.46 %	87.83 %
CNN + Atención suave	90.22 %	89.92 %	87.00 %	90.62 %	88.78 %
CNN + Atención dura	**94.22** %	**96.12** %	**94.62** %	**91.67** %	**93.12** %

Figura 3.8: Resultados de la validación cruzada de los modelos propuestos en [Aguilar, 2022]. Fuente: [Aguilar, 2022]

El proceso de evaluación del modelo de predicción mediante validación cruzada sigue los siguientes pasos. En primer lugar, se divide el conjunto de datos en las particiones de entrenamiento y prueba sin sesgos. Para conseguir este punto, se emplea la función *StratifiedGroupKFold* de la librería *sklearn.model_selection*, la cuál permite dividir el conjunto de datos en un número de particiones y asegura que las muestras que comparten una misma característica, en este caso la variable *groups* de *CancerDetectionDataset*, no se repartan entre distintas particiones. La variable *groups* muestra el nombre de la carpeta en la que se encuentra la imagen. Esto es relevante ya que las muestras reales se encuentran dentro de una misma carpeta junto con sus muestras aumentadas, por lo que si dos muestras tienen el mismo *groups* significa que provienen de la misma muestra real. A continuación, el conjunto de prueba elimina aquellas muestras cuyo nombre contenga "*augmented*" para que esta partición esté formada únicamente por muestras reales.

Tras obtener los conjuntos de entrenamiento y prueba, se particiona entrenamiento de nuevo en dos: entrenamiento y validación. Esto se lleva a cabo de la misma forma que se dividieron los dos primeros conjuntos (sin sesgos y sin imágenes aumentadas en el conjunto de validación). El objetivo es evitar desperdiciar muestras durante la validación cruzada, por lo que se coge una pequeña parte del entrenamiento como conjunto de validación para los GANs (*KID y FID* necesitan un conjunto de datos externos) y después se integra de nuevo al conjunto de entrenamiento para entrenar el modelo predictivo, en este momento las imágenes aumentadas se encuentran presente en el conjunto de validación una vez más.

Una vez que se ha dividido el conjunto entre entrenamiento y validación, el primero se particiona de nuevo entre muestras sanas y enfermas para alimentar cada partición a

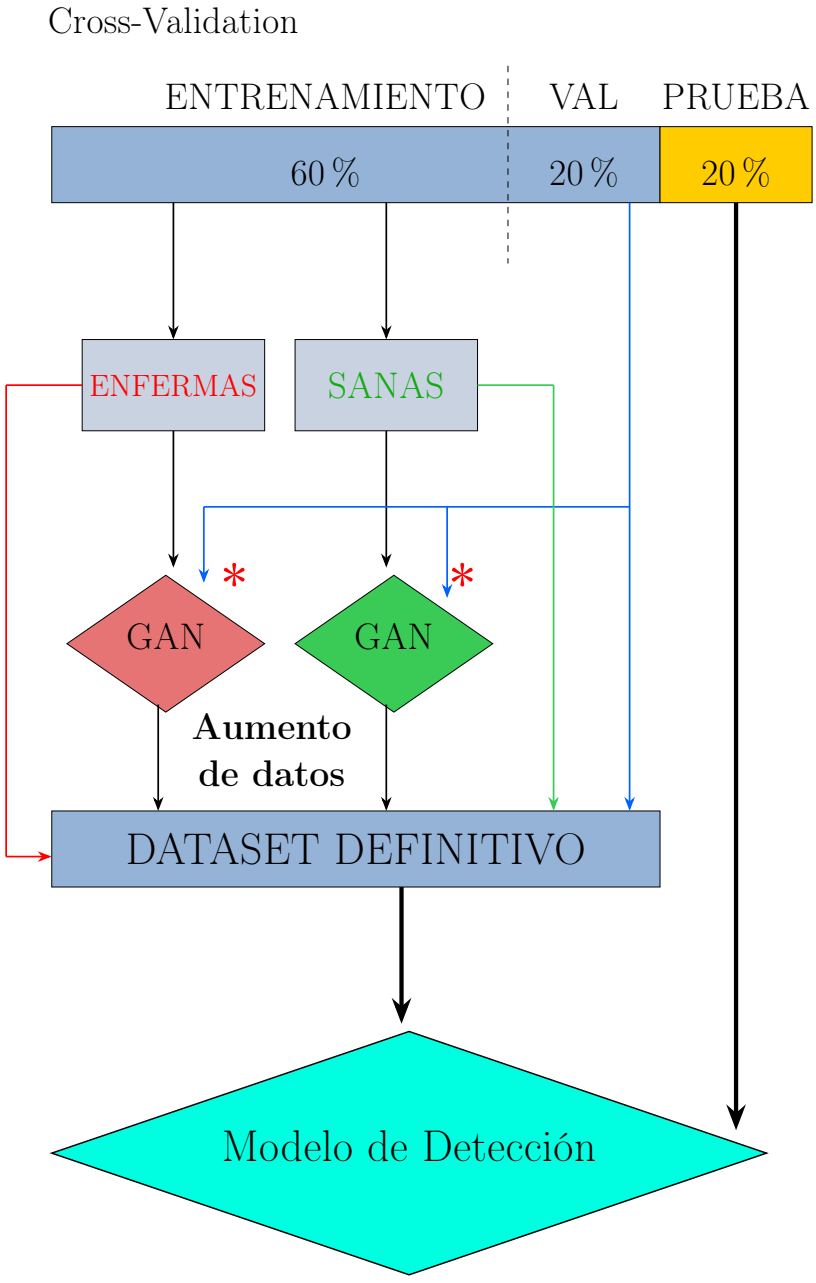
su modelo GAN. Se asigna la configuración de hiperparámetros correspondiente (primero modelo de muestras enfermas y después sanas) y se comienzan a entrenar ambos modelos GAN. Tras entrenar cada uno, se almacena en una variable el generador con el aprendizaje obtenido. Con estas variables, se comienzan a generar las imágenes del aumento de datos tanto sanas como enfermas, haciendo uso de la función *data_ augmentation* (explicada en la sección 3.5) y usando el conjunto auxiliar de validación como referencia para *KID y FID*. Una vez generadas las imágenes,siguiendo el proceso ya descrito, se mezclan con las del conjunto de entrenamiento y validación y se modifica la variable *transform* del conjunto final (tipo de dato *CancerDetectionDataset*) para que las imágenes se extraigan en tamaño 56x56 píxeles. Esto es debido a que el modelo predictivo recibe las imágenes en esa resolución.

Una vez generado el conjunto de datos final (reales y generadas en 56x56 píxeles) este se alimenta al modelo predictivo para su entrenamiento y evaluación. En este proceso, se almacenarán los siguientes datos:

- Modelo predictivo ya entrenado.
- Métricas de evaluación: Exactitud, Especificidad, Precisión, Exhaustividad y Puntuación F1. Para cada una de estas variables se devuelven los valores obtenidos en cada pliegue y además se imprimirá la media de todos los pliegues.
- Predicciones realizadas y etiquetas reales. Estos datos permitirán, más adelante, obtener la curva ROC y el valor AUC y la matriz de confusión.

Este proceso se ha llevado a cabo añadiendo una función *subset* a la variable encargada de gestionar el conjunto de datos y tiene el objetivo de devolver un subconjunto de los mismos. Para ello, se le proporcionan los IDs de las muestras a incluir en el subconjunto y la función devuelve otro tipo de dato *CancerDetectionDataset* con las muestras que se le han indicado. Gracias a esta función se han podido llevar a cabo de manera eficiente los procedimientos de particionar conjuntos de datos y división de muestras sanas y enfermas.

El flujo descrito anteriormente se resume en la fig. 3.9. En esta, se observa que, en primer lugar, se divide entrenamiento y prueba. A continuación, se divide entrenamiento y validación, haciendo que este último se componga de un 20 % del total de los datos. El conjunto de entrenamiento se separa entre sanas y enfermas, que se utilizan para entrenar a sus respectivos modelos GANs. En este punto, el conjunto de validación se utilizará para evaluar *KID* y *FID* y para la generación de imágenes en el aumento de datos. Finalmente, entrenamiento, validación (con las imágenes aumentadas) y las imágenes sintéticas se unifican en un mismo conjunto de datos y se alimenta al modelo predictivo para el entrenamiento y la evaluación se llevará a cabo con el conjunto de prueba.



* La validación NO tiene aumento de datos en este punto

Figura 3.9: Flujo seguido en la validación cruzada

Tras múltiples ejecuciones del flujo propuesto, se observa que, a pesar de que la afinación de hiperparámetros contribuye a reducir la posibilidad de fallos de convergencia, esta problemática persiste. Tal y como se comentó en la sección 2.1.2, los GANs son muy inestables en el entrenamiento [Ian J. Goodfellow et al., 2014], especialmente cuando el conjunto de datos es muy reducido. Ante esta limitación inherente, se decide mantener las imágenes generadas en el conjunto definitivo independientemente de si el modelo ha experimentado un fallo de convergencia o no. Esta decisión se fundamenta en el hecho de que, en la mayoría de casos, el fallo solo se produce en uno de los modelos GANs, sin comprometer significativamente el conjunto de datos. Además, se implementa como una forma de evitar el aumento exponencial del tiempo de ejecución del experimento, debido a que se debe entrenar el GAN de nuevo. Esta inestabilidad se acentúa cuando el número de imágenes del conjunto de datos es reducido, lo que hace muy difícil eliminarla por completo [Tero Karras et al., 2020].

Una vez finalizado el proceso de entrenamiento y validación, se desarrolla el programa *apply_grad_cam.py*, cuyo objetivo es aplicar las técnicas de Grad-CAM sobre una selección de imágenes empleando los modelos previamente entrenados durante la validación cruzada. Este programa permite comparar las zonas que reciben mayor atención según el número de imágenes sintéticas introducidas en el conjunto de datos.

3.9. Entrenamiento completo y evaluación

Como ya se expuso en el capítulo introductorio, con el objetivo de reducir posibles sesgos en los resultados y mejorar la fiabilidad del análisis, se ejecuta la validación cruzada 10 veces, obteniendo todas las métricas de evaluación del modelo predictivo y realizando sobre ellos un análisis estadístico. De esta forma, no solo se comprobará el impacto de las imágenes sintéticas en el modelo predictivo, sino que también se comprueba la consistencia de la puntuación y su variación a lo largo de las ejecuciones.

Todas las ejecuciones de este proyecto se han realizado en el superordenador de la UNED, modelo "4G4 Dual Intel Xeon High Performance Computer", denominado "Tesla", el cuál tiene las siguientes especificaciones:

- 2 procesadores Intel Xeon Silver.
- 2 tarjetas GPU NVIDIA Tesla V100 con 5120 núcleos de computación cada una.
- 96 GB de memoria RAM.

Se puede acceder a los recursos de la máquina a través de un servidor con interfaz JupyterLab y base Debian. Gracias a esta máquina se han podido llevar a cabo todos los experimentos del proyecto y las ejecuciones finales. Como se ha comentado, los GANs son modelos

que consumen una gran cantidad de recursos computacionales, por lo que las potentes especificaciones de este equipo han permitido que los tiempos de ejecución hayan sido asumibles. Mencionar también que en los últimos meses esta máquina ha sufrido ciertos problemas que han retrasado el desarrollo del proyecto, ya que durante un tiempo se produjo un fallo que reiniciaba el servidor por completo y en otras ocasiones la memoria se colapsaba con la ejecución de varios procesos.

Para las ejecuciones definitivas se diseña un programa que realiza un bucle de 10 iteraciones al proceso de validación cruzada descrito en la sección anterior. En cada iteración se almacenan las predicciones realizadas, las etiquetas reales y las métricas obtenidas (exactitud, especificidad...). De esta manera, a la finalización de las 10 ejecuciones se obtiene un análisis estadístico de las métricas obtenidas y a partir de las predicciones y las etiquetas se genera la matriz de confusión (mapa de calor) y la curva ROC y el valor AUC. En la fig.3.10 se pueden observar las gráficas generadas para la matriz de confusión y la curva ROC AUC.

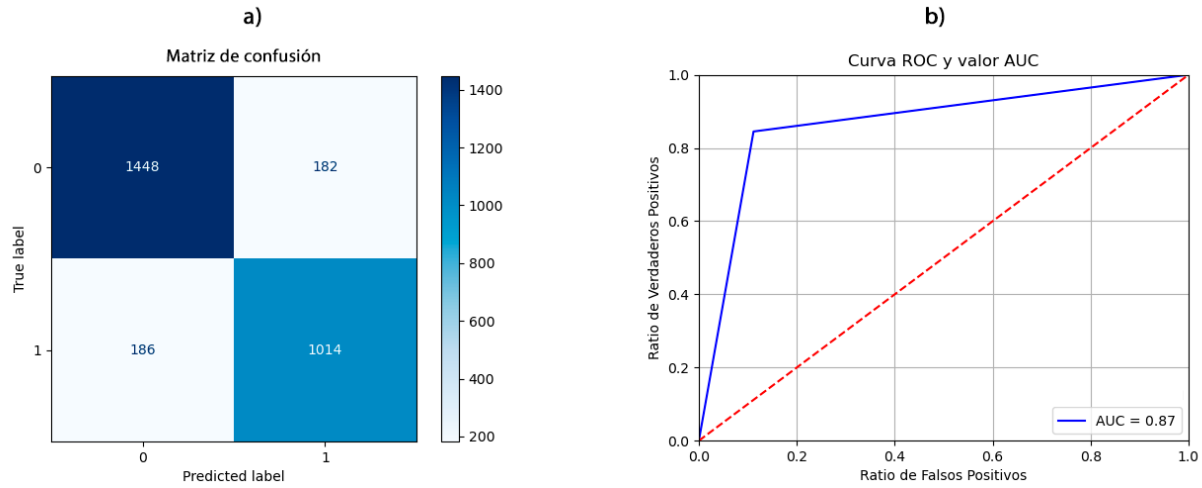


Figura 3.10: Gráficas generadas en el programa que ejecuta el proceso completo. a) Matriz de confusión. b) Curva ROC AUC.

Una vez implementado el proceso final para el entrenamiento, evaluación y obtención de los resultados, es hora de definir una serie de pruebas para el estudio que se está llevando a cabo. El objetivo reside en conocer la eficacia de las imágenes sintéticas a través de los resultados del modelo predictivo, comprobando así si es posible mejorar su rendimiento cuando se añaden imágenes sintéticas al conjunto de datos. Se van a definir 5 pruebas:

- 0 % imágenes sintéticas: conjunto de datos base. Esta ejecución servirá como referencia para las siguientes pruebas. Como se comentó anteriormente, esta investigación adopta una metodología que minimiza los sesgos en la evaluación en mayor medida que el trabajo previo. Por ello, es imprescindible obtener los resultados del conjunto base para

poder analizar los resultados en comparación con las pruebas de imágenes sintéticas de forma rigurosa.

- ∼25 % imágenes sintéticas: conjunto de datos + 768 imágenes sintéticas.
- ∼50 % imágenes sintéticas: conjunto de datos + 1536 imágenes sintéticas.
- ∼75 % imágenes sintéticas: conjunto de datos + 2304 imágenes sintéticas.
- ∼100 % imágenes sintéticas: conjunto de datos + 3072 imágenes sintéticas.

En cada ejecución se genera un porcentaje de imágenes sintéticas respecto al total del conjunto de datos (3113), con el fin de evaluar el impacto de distintas cantidades introducidas. El número de imágenes sintéticas no coincide exactamente con el porcentaje debido a que este valor debe ser múltiplo de 64, por la manera en que se generan lotes de 64 imágenes en el aumento de datos. Indicar que una ejecución completa con el conjunto base requiere aproximadamente 40 minutos, mientras que añadir cualquier número de imágenes sintéticas hace que el proceso alcance alrededor de los 4 días. Esto es debido a que cada modelo GAN demora entre 40-60 minutos en entrenar, por lo que si cada pliegue dura unas 2 horas, hay 5 pliegues en cada validación cruzada y son 10 iteraciones, se obtienen unas 100 horas: aproximadamente 4 días de cómputo. Esta situación, junto con el hecho de que en ocasiones la máquina ha sufrido problemas, ha hecho que la ejecución de las 5 pruebas sea una tarea prolongada y extensa.

Capítulo 4

Resultados

En el siguiente apartado se presentan los resultados obtenidos a lo largo de las 5 ejecuciones experimentales realizadas. En este se recogen las métricas de evaluación asociadas al modelo generativo, las métricas de evaluación del modelo predictivo, los tiempos de ejecución de cada experimento, los mapas de atención obtenidos a través GradCAM y la frecuencia de fallos de convergencia encontrados durante la ejecución de los 5 experimentos. Finalmente, se lleva a cabo un análisis de los resultados que permite extraer conclusiones sobre el impacto del uso de imágenes sintéticas en el rendimiento de un modelo predictivo.

4.1. Resultados de los GANs

En este segmento se presentan los datos representativos de los modelos generativos durante los experimentos. Considerando que en cada uno se entrenan 100 modelos *StyleGAN*, se selecciona aleatoriamente una instancia concreta: el experimento correspondiente al 100 % de imágenes sintéticas durante la décima ejecución y el quinto pliegue. Se muestran los datos de ambos modelos generativos de dicha ejecución, tanto de muestras sanas como enfermas, con el objetivo de ofrecer una visión cualitativa mediante las muestras generadas y cuantitativa a través de las métricas recogidas.

En relación con las imágenes sintéticas, la fig. 4.1 expone ejemplos de muestras sanas producidas con el modelo que entrena con este subconjunto, mientras que la fig. 4.2 expone las enfermas, producidas por el modelo que entrena con el subconjunto de enfermas. Como se puede apreciar, ambos modelos han logrado sintetizar imágenes de gran calidad. El tiempo medio de entrenamiento fue de aproximadamente 60 minutos para el modelo de muestras sanas y 40 minutos para el muestras enfermas.

En cuanto a las métricas de evaluación de calidad de las imágenes sintéticas, la fig. 4.3 presenta la evolución de los valores *KID/FID* correspondientes a los modelos entrenados con sanas y enfermas, para dicho ejemplo seleccionado. Estas métricas reflejan una disminución

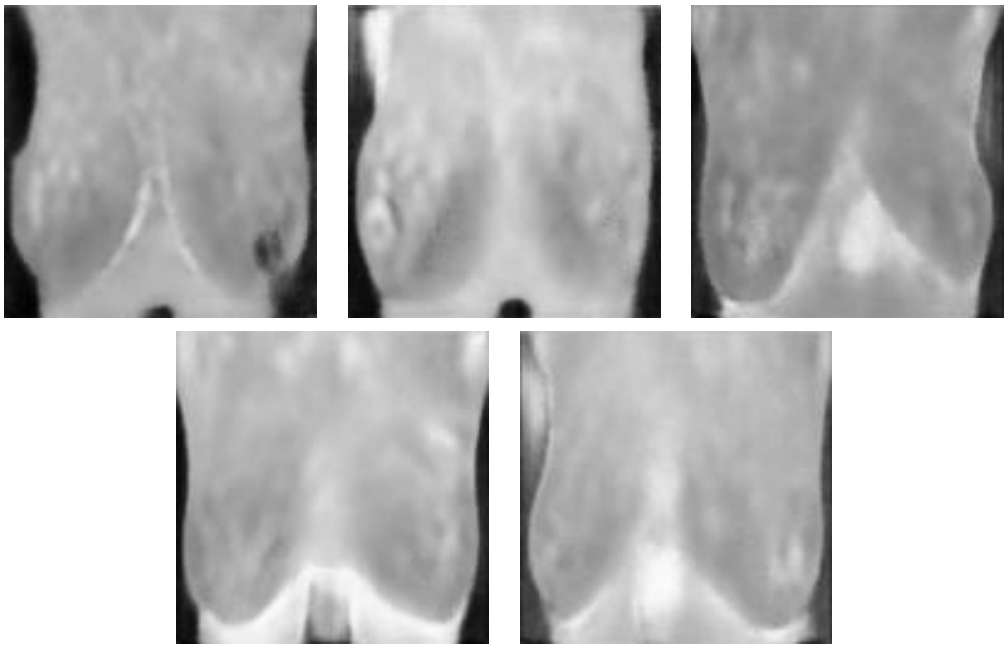


Figura 4.1: Imágenes sanas generadas durante la ejecución del experimento del 100 % (3072). Estas imágenes corresponden a la ejecución número 10 y al quinto pliegue (última ejecución dele experimento).

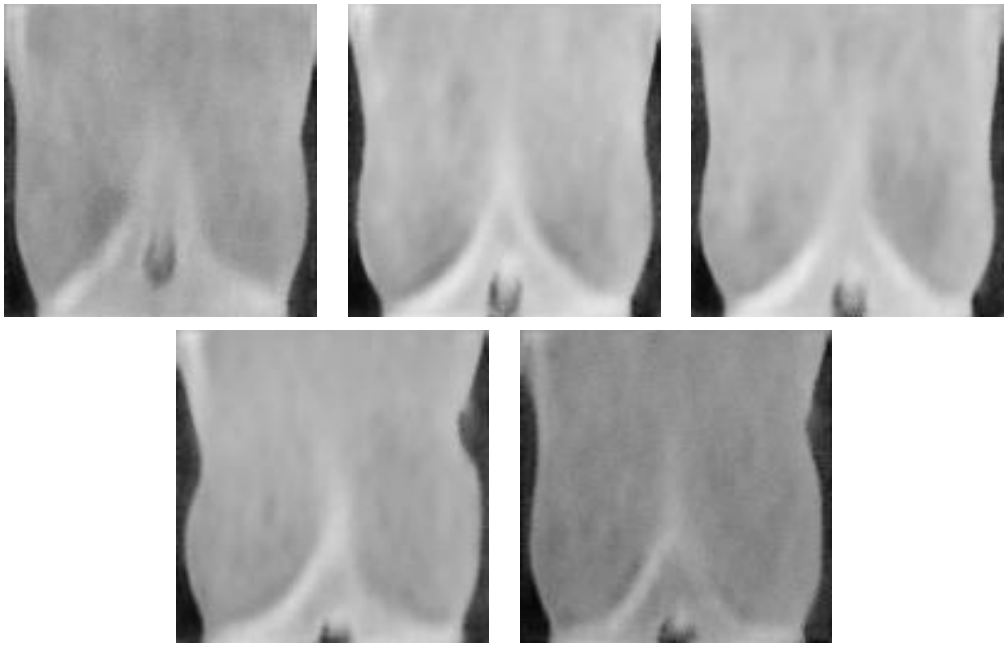


Figura 4.2: Imágenes enfermas generadas durante la ejecución del experimento del 100 % (3072). Estas imágenes corresponden a la ejecución número 10 y al quinto pliegue (última ejecución del experimento).

significativa a lo largo del entrenamiento, alcanzando valores en torno a 0.2 para el *KID* y entre 250 y 300 para el *FID*, lo que indica muy buenos resultados en cuanto a la calidad de las imágenes generadas. Cabe mencionar de nuevo la casuística que posee la métrica del FID,

donde esta obtiene sesgos cuando se presenta ante conjuntos de datos pequeños. Debido a esto, KID es la métrica principal empleada para el análisis e implementación de procesos en este proyecto.

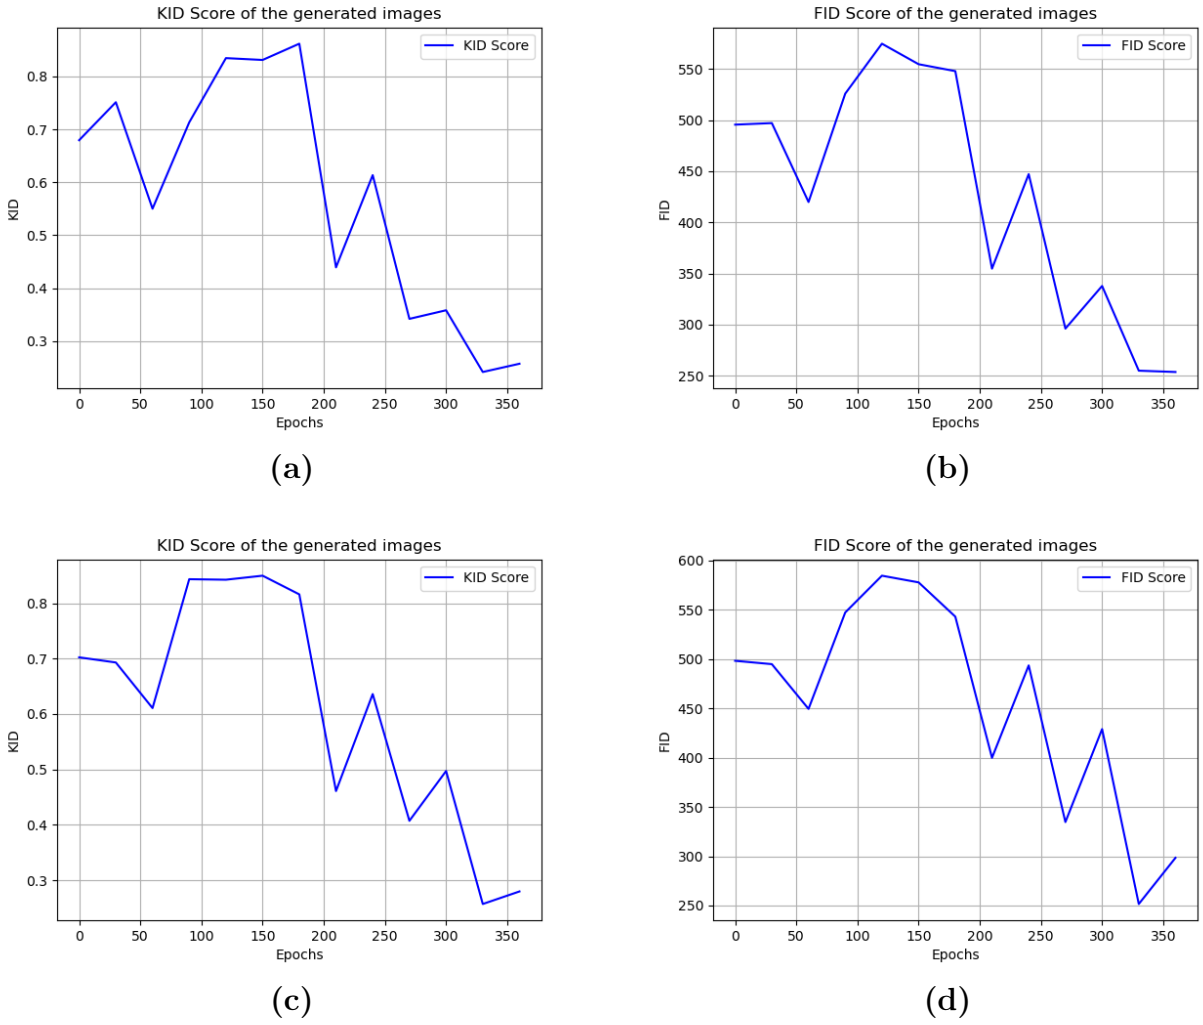
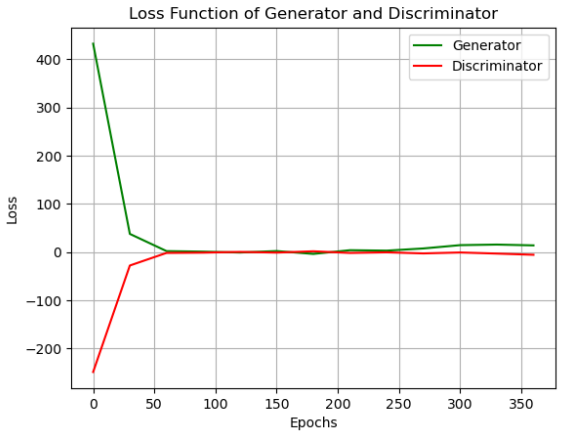
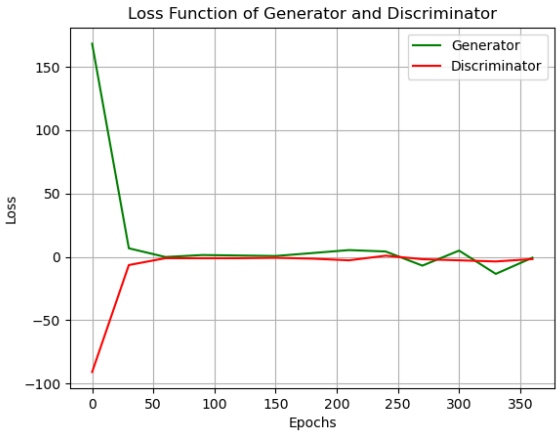


Figura 4.3: *KID/FID Score* para los GANs de las imágenes sanas y enfermas del experimento del 100 % durante la ejecución 10 y el pliegue 5. (a) KID Score del modelo de muestras sanas (b) FID Score del modelo de muestras sanas (c) KID Score del modelo de muestras enfermas (d) FID Score del modelo de muestras enfermas.

Finalmente, se presenta la evolución de la función de pérdida para ambos modelos generativos (fig. 4.4). Tal y como se ha indicado anteriormente, Wasserstein no es una función fiable para medir el rendimiento de los modelos ni compararlos, por lo que se presenta en esta sección pero no se llevan a cabo análisis sobre estos.



(a) Función de pérdida de las sanas



(b) Función de pérdida de las enfermas

Figura 4.4: Función de pérdida del modelo de sanas y enfermas del experimento del 100 % durante la ejecución 10 y el pliegue 5.

4.2. Métricas de evaluación del modelo predictivo

A continuación se presentan los resultados obtenidos por el modelo predictivo en función de las métricas definidas en el capítulo anterior, para cada una de las ejecuciones realizadas: 0 % de imágenes sintéticas, ∼25 % (768 imágenes), ∼50 % (1536), ∼75 % (2304) y ∼100 % (3072). La tabla 4.1 refleja los resultados alcanzados, siendo la primera columna el porcentaje de imágenes sintéticas, la segunda el tipo de dato estadístico: media, varianza o desviación típica y las siguientes columnas recogen las métricas de evaluación: Exactitud, Especificidad, Precisión, Exhaustividad y Puntuación F1. En cada columna se destaca en negrita el mejor valor arrojado, para facilitar la comparación. Cabe señalar que los modelos predictivos se entrenan bajo los mismos hiperparámetros que los utilizados en el proyecto [Aguilar, 2022]: 50 épocas, función de pérdida de entropía cruzada y 0.001 de tasa de aprendizaje con el optimizador Adam.

Antes de analizar en detalle los resultados, es importante establecer el criterio con el que se considera que se produce una mejora respecto a la ejecución base (0 % generadas). Se entenderá como tal todo resultado que presente una media superior acompañada de una desviación típica y varianza inferiores o similares. Este enfoque permite valorar tanto la eficacia como la consistencia de los resultados. En lo que respecta a la exactitud, el experimento base presenta una media de 0.865, con una varianza de 0.105 y una desviación típica de 0.324. Como se observa en la tabla 4.1, las ejecuciones de 50 % y 100 % son las más destacadas en términos de mejora y estabilidad, ya que ambas consiguen 0.87 de media, una varianza de 0.132 y 0.128 y una desviación típica de 0.358 y 0.364, respectivamente cada uno. Estos valores indican un rendimiento más eficaz sin una penalización significativa en variabilidad. Se obtiene que la inclusión de imágenes generadas mediante GANs ha tenido un

efecto positivo en el rendimiento del modelo predictivo en cuanto a exactitud, especialmente las configuraciones de 50 % y 100 %. Esta métrica, como se explicó anteriormente, representa un buen desempeño en la detección general de ambos casos.

En lo que respecta a la especificidad, el experimento sin imágenes sintéticas presenta una media de 0.885, con una varianza de 0.003 y una desviación típica de 0.057. Todas las configuraciones con generación de imágenes superan esta media, manteniendo además niveles de varianza y desviación muy similares. Como por ejemplo el experimento con 100 % de imágenes sintéticas, que obtiene una media de 0.897, una varianza de 0.003 y una desviación de 0.059. No obstante, se destaca la ejecución de 75 %, que obtiene una media de 0.896, una varianza de 0.003 y una desviación 0.055, para esta métrica, las imágenes sintéticas mejoran el rendimiento del modelo predictivo tanto en la media como en la consistencia de este valor. La especificidad representa la capacidad de un modelo para detectar correctamente los casos negativos (sujetos sanos).

En relación con la métrica de precisión, el conjunto base alcanza una media de 0.848 con una varianza de 0.004 y una desviación de 0.065. Se destaca el experimento de 100 % por presentar una mejora notable con una media de 0.862, una varianza de 0.004 y una desviación de 0.067, lo que evidencia una mejora sin pérdida de consistencia. En contraste, mencionar el experimento de 75 % que empeora todos los resultados, obteniendo 0.841 de media y 0.018 y 0.135 en la varianza y desviación respectivamente. Esta métrica representa la proporción de predicciones positivas verdaderas respecto a las predicciones positivas.

En cuanto a la métrica de la exhaustividad, el modelo base presenta una media de 0.838 con una varianza de 0.006 y una desviación de 0.08. Los experimentos con imágenes sintéticas muestran mayor dificultad para superar estos valores. Sólo los experimentos con 25 % y 50 % de imágenes sintéticas lo logran: 25 % con una media de 0.841, varianza de 0.008 y desviación de 0.09 y el mejor resultado, 50 %, con media de 0.845, varianza de 0.008 y desviación de 0.09. Estos valores presentan una mejora del rendimiento sin una penalización excesiva en la consistencia del mismo. Esta métrica refleja la capacidad del modelo de detectar correctamente muestras positivas, y su mejora implica una reducción del riesgo de falsos negativos, lo que supone una cuestión crítica en contextos clínicos. Estos resultados demuestran que la generación de imágenes contribuye positivamente a la detección de muestras positivas incluso cuando el número de imágenes enfermas es menor que el de sanas.

El conjunto base presenta una puntuación F1 con media de 0.839 y varianza de 0.001 y desviación de 0.041, mientras que el mejor resultado obtenido con el 50 % de imágenes sintéticas consiste en una media de 0.845, una varianza de 0.003 y una desviación de 0.058. Esta métrica combina la precisión y la exhaustividad en un solo valor para reflejar el equilibrio entre ambas. El aumento logrado en esta indica que toda la metodología implementada en este trabajo ha sido efectiva, mejorando el rendimiento del modelo a través de aumento

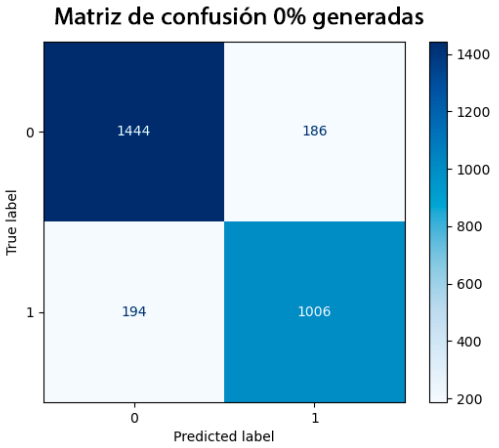
Imgs. Gen.		Exactitud	Especificidad	Precisión	Exhaustividad	Punt. F1
0 %	**Media**	0.865	0.885	0.848	0.838	0.839
	Varianza	0.105	0.003	0.004	0.006	0.001
	Desv.Típica	0.324	0.057	0.065	0.080	0.041
∼25 % (768)	**Media**	0.867	0.888	0.852	0.841	0.841
	Varianza	0.226	0.004	0.006	0.008	0.003
	Desv.Típica	0.475	0.068	0.083	0.090	0.058
∼50 % (1536)	**Media**	**0.870**	0.887	0.859	**0.845**	**0.845**
	Varianza	**0.132**	0.005	0.005	**0.008**	**0.001**
	Desv.Típica	**0.364**	0.073	0.076	**0.090**	**0.040**
∼75 % (2304)	**Media**	0.869	**0.896**	0.841	0.833	0.833
	Varianza	0.291	**0.003**	0.018	0.020	0.016
	Desv.Típica	0.539	**0.055**	0.135	0.143	0.126
∼100 % (3072)	**Media**	**0.870**	0.897	**0.862**	0.835	0.844
	Varianza	**0.128**	0.003	**0.004**	0.007	0.002
	Desv.Típica	**0.358**	0.059	**0.067**	0.083	0.045

Tabla 4.1: Métricas obtenidas en la evaluación final por el modelo predictivo usando un número determinado de imágenes generadas.

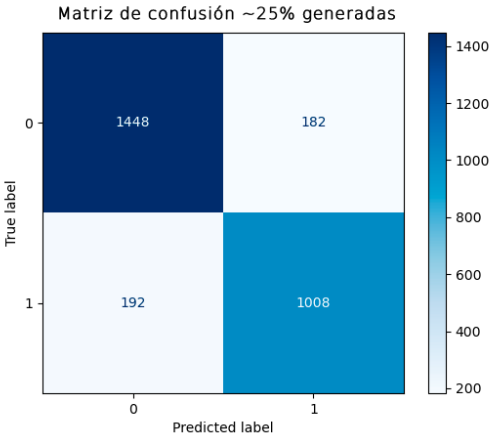
de datos mediante imágenes sintéticas. Aún así, para concluir que esta técnica mejora los resultados del modelo predictivo es necesario realizar un mayor número de experimentos que permitan aumentar la fiabilidad y consistencia de los resultados.

A continuación, se analiza la matriz de confusión obtenida en los diferentes experimentos, presentadas en la fig. 4.5. En cuanto a los verdaderos negativos (TN- primera fila primera columna), el modelo base obtiene un acierto de 1444 muestras, mientras que el resto alcanza 1448, 1448, 1461 y 1463 respectivamente, siendo el experimento con el 100 % de generadas el que mejor identifica los verdaderos negativos. Pasando a los falsos positivos, FP (primera fila, segunda columna) la base obtiene 186, mientras que el resto de ejecuciones recogen 182, 182, 169 y 167 respectivamente, siendo de nuevo la ejecución del 100 % de generadas la mejora para minimizar los FP. Para el caso de los falsos negativos, el conjunto base obtiene 194, mientras que el resto 192, 186, 200 y 200 respectivamente, es en este caso que el 50 % de generadas se presenta como el mejor experimento para reducir falsos negativos. En cuanto a los verdaderos positivos, la base posee 1006 muestras correctas mientras que el mejor resultado lo posee el experimento de 50 % con 1014.

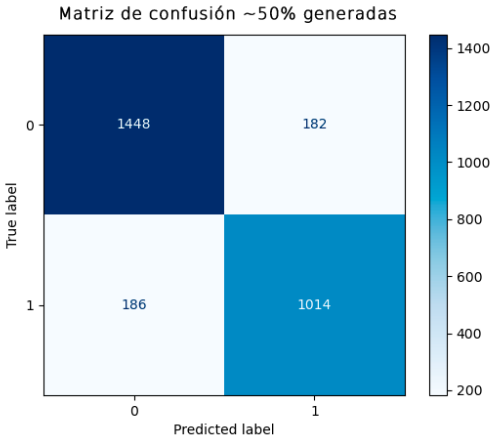
Finalmente, en la fig. 4.6 se presentan las curvas ROC y los valores AUC correspondientes a cada experimento. El modelo entrenado con el conjunto base posee un AUC de 0.86 al igual que los experimentos con 25 % y 75 % de imágenes sintéticas. Sin embargo, tanto 50 % como 100 % logran aumentar ligeramente este valor a 0.87. Estos resultados indican que los modelos son altamente efectivos para distinguir entre cada tipo de clase del conjunto de datos, y gracias al aumento de datos por GANs se ha aumentado este valor de manera liviana. Para la obtención de estos gráficos, se utilizó el mismo procedimiento que para las matrices de confusión: considerando las etiquetas junto con las predicciones realizadas.



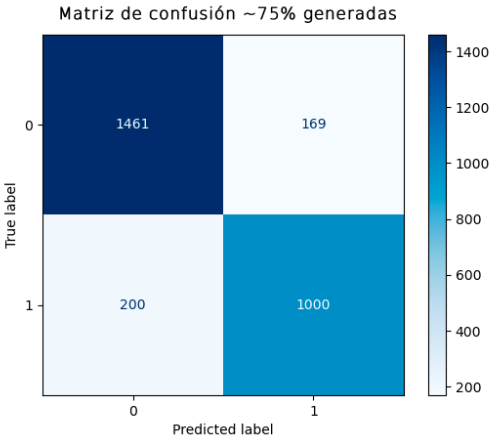
(a) 0 %



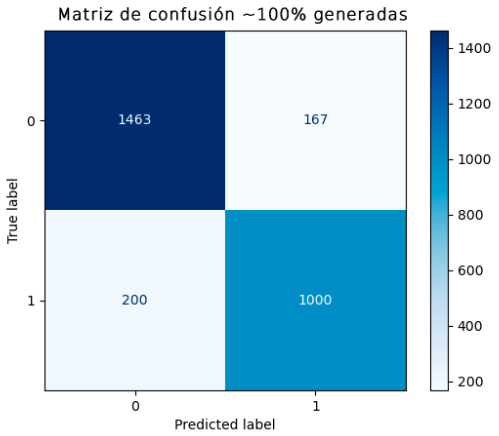
(b) ~25 %



(c) ~50 %

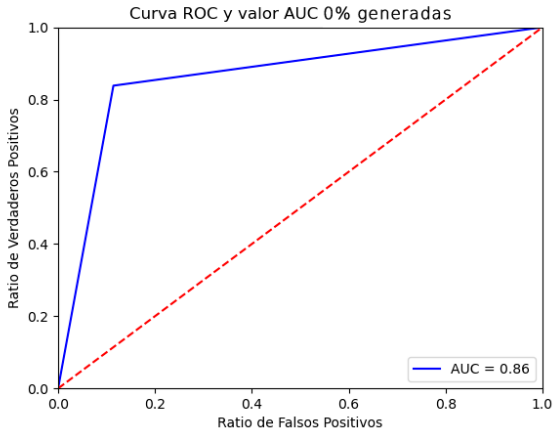


(d) ~75 %

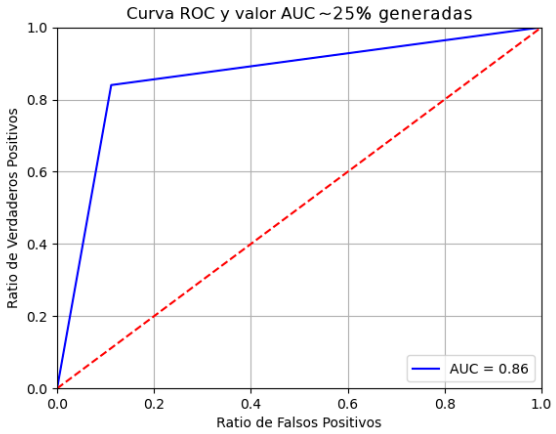


(e) ~100 %

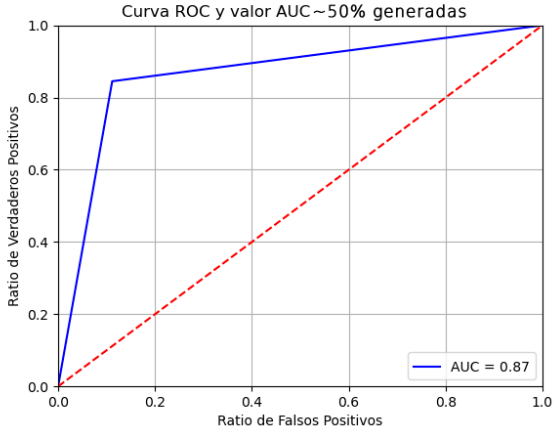
Figura 4.5: Matriz de confusión para los modelos predictivos entrenados con distinto número de imágenes sintéticas en el conjunto de datos: **(a)** 0 % **(b)** ~25 % **(c)** ~50 % **(d)** ~75 % **(e)** ~100 %



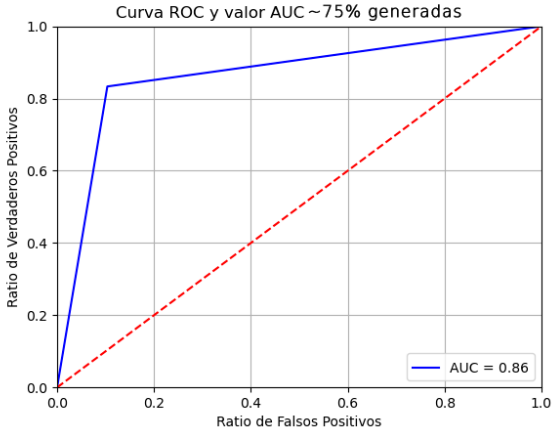
(a) 0 %



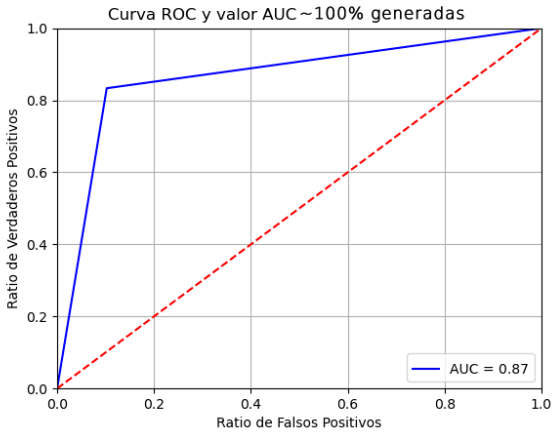
(b) ∼25 %



(c) ∼50 %



(d) ∼75 %



(e) ∼100 %

Figura 4.6: Curva ROC y valor AUC para los modelos de predicción entrenados con distinto número de imágenes sintéticas en el conjunto de datos: **(a)** 0 % **(b)** ∼25 % **(c)** ∼50 % **(d)** ∼75 % **(e)** ∼100 %

4.3. Tiempos de ejecución

A lo largo del siguiente apartado se van a discutir los tiempos de ejecución de cada uno de los experimentos. Como se puede ver en la fig. 4.7, los tiempos fueron los siguientes:

- 0 % imágenes sintéticas: 66 minutos, 1 hora 6 minutos.
- 25 % imágenes sintéticas: 5490 minutos, 91.5 horas, 3.81 días.
- 50 % imágenes sintéticas: 5584 minutos, 93 horas, 3.87 días.
- 75 % imágenes sintéticas: 5873 minutos, 97.8 horas, 4 días.
- 100 % imágenes sintéticas: 5883 minutos, 98 horas, 4 días.

El tiempo total de ejecución de los experimentos finales asciende a 22.896 minutos, lo que equivale aproximadamente a 16 días. Se observa una relación directa entre el número de imágenes sintéticas y el tiempo de ejecución. Esta variación se atribuye principalmente al procedimiento diseñado para el aumento de datos, explicado en la sección 3.5, en el cuál se generan lotes de 64 imágenes y se almacenan los que alcancen un umbral definido. En caso de no alcanzarse, se repetirá el procedimiento 3 veces antes de almacenar el último lote generado. En consecuencia, cuanto mayor es el número de imágenes a generar, mayor es el número de iteraciones requeridas para obtener conjuntos que cumplan con el umbral definido.

Como se mencionó en el capítulo anterior, los tiempos de ejecución presentados fueron posibles gracias a las especificaciones de la máquina *Tesla*. En equipos con mucha menor RAM o GPU, la realización de este proyecto hubiera sido inviable. Los resultados expuestos en este capítulo (métricas, Grad-CAM, étc.) provienen de una ejecución final donde la máquina tuvo una serie de problemas (sobrecalentamiento de la GPU, gestión de recursos, étc.) por lo que los tiempos de ejecución duplicaron o incluso triplicaron a los mostrados en este apartado. Este contratiempo fue confirmado con la persona encargada de la gestión y administración de la máquina *Tesla*: José Ramón Álvarez Sánchez, quién reportó lentitud y sobrecalentamiento. Dado que esta situación fue excepcional, se han presentado en esta sección los tiempos de una ejecución anterior también válida e idéntica, donde la máquina no presentó problemas en sus recursos y se ejecutó de forma esperada. Los tiempos de ejecución de esta iteración anómala se presentan a continuación, destacando que a partir de la ejecución con 50 % los problemas mencionados se presentaron. Esa es la razón por la que las dos primeras ejecuciones tienen tiempos muy similares a los de la ejecución normal (fig.4.7):

- 0 % generadas: 66 minutos, 1 hora 6 minutos.
- 25 % generadas: 5438 minutos, 90.6 horas, 3.77 días.

- 50 % generadas: 15722 minutos, 262 horas, 10.91 días.
- 75 % generadas: 7595 minutos, 126.5 horas, 5.27 días.
- 100 % generadas: 12503 minutos, 208.3 horas, 8.68 días.

El tiempo total de las ejecuciones anómalas fue de 41324 minutos, equivalente a aproximadamente 28 días y medio. Como se observa, estas cifras son incoherentes ya que las ejecuciones que generan mayor número de imágenes no son las que más tiempo duran, como por ejemplo el 50 % de generadas que es el experimento con mayor tiempo, alcanzando casi 11 días.

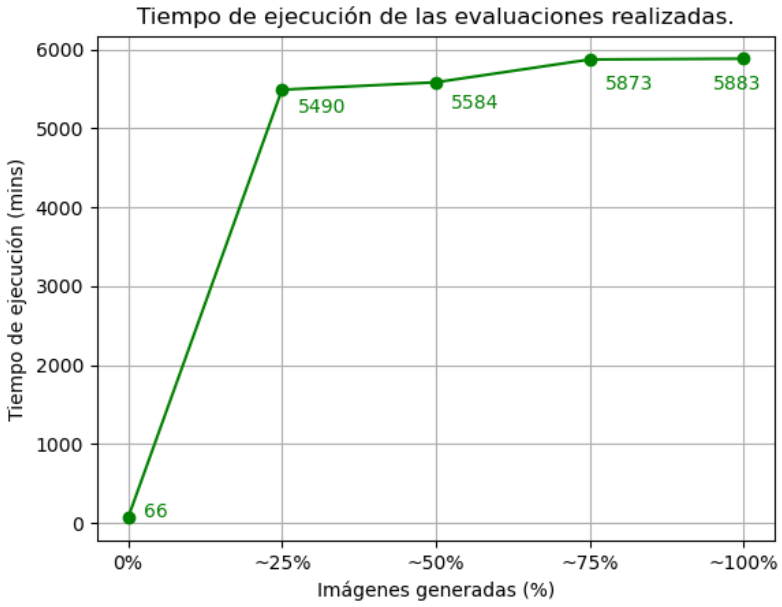


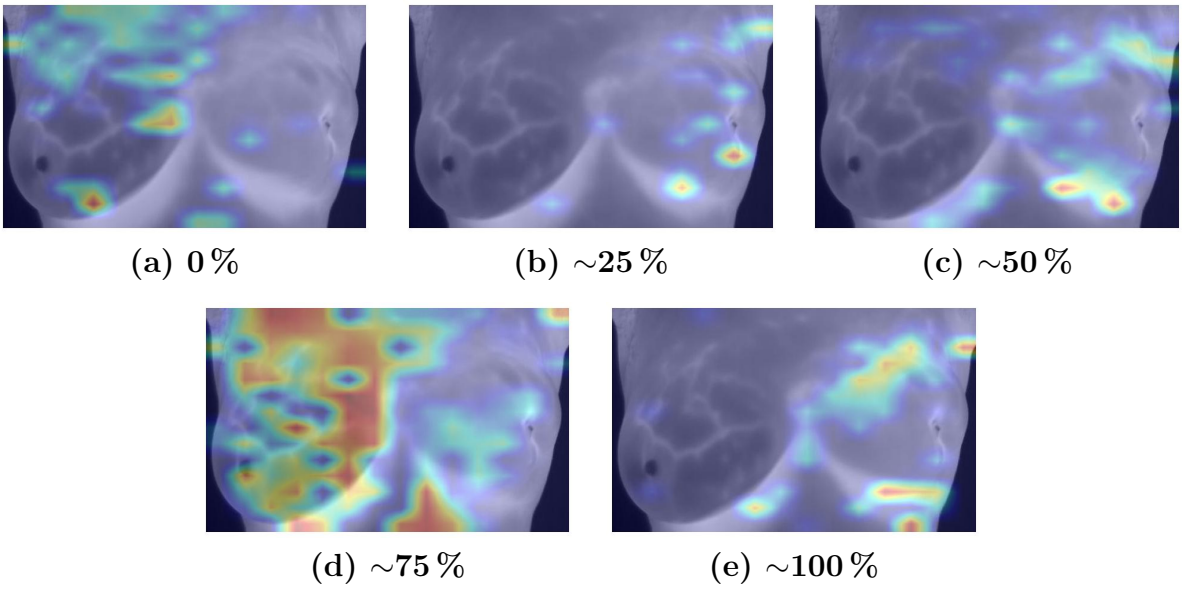
Figura 4.7: Tiempo de ejecución de las distintas ejecuciones finales.

4.4. Grad-CAM

En esta sección se aplica la técnica del Grad-CAM sobre dos pacientes enfermas: 192 y 245 utilizando un modelo predictivo ya entrenado en cada experimento. En este contexto, se utilizan los modelos ya entrenados de la ejecución 8 de la validación cruzada. Esto permitirá comparar las regiones con mayor atención según el número de imágenes sintéticas utilizadas en el entrenamiento. Como se explicó en el capítulo 2, la atención dura se centra en zonas específicas con mayor relevancia para el diagnóstico, lo que en este contexto pueden indicar la presencia de anomalías [Aguilar, 2022].

En la fig. 4.8 se presentan las imágenes de Grad-CAM correspondientes a los modelo predictivos entrenados con distintos porcentajes de imágenes sintéticas. El modelo con el

conjunto base centra su atención en la parte baja del pecho izquierdo como se puede ver en la fig. 4.8 a. El modelo del 75 % (apartado d), también pone una gran atención a toda la zona de ese pecho. No obstante, los modelos entrenados con 25 %, 50 % y 100 % de imágenes sintéticas (apartados b, c y e respectivamente) se centran en la zona baja del pecho derecho. Este pecho presenta una notable diferencia de color respecto a la zona inferior del pecho izquierdo. Puede que estos modelos utilicen esta característica para clasificar a la paciente como "enferma".



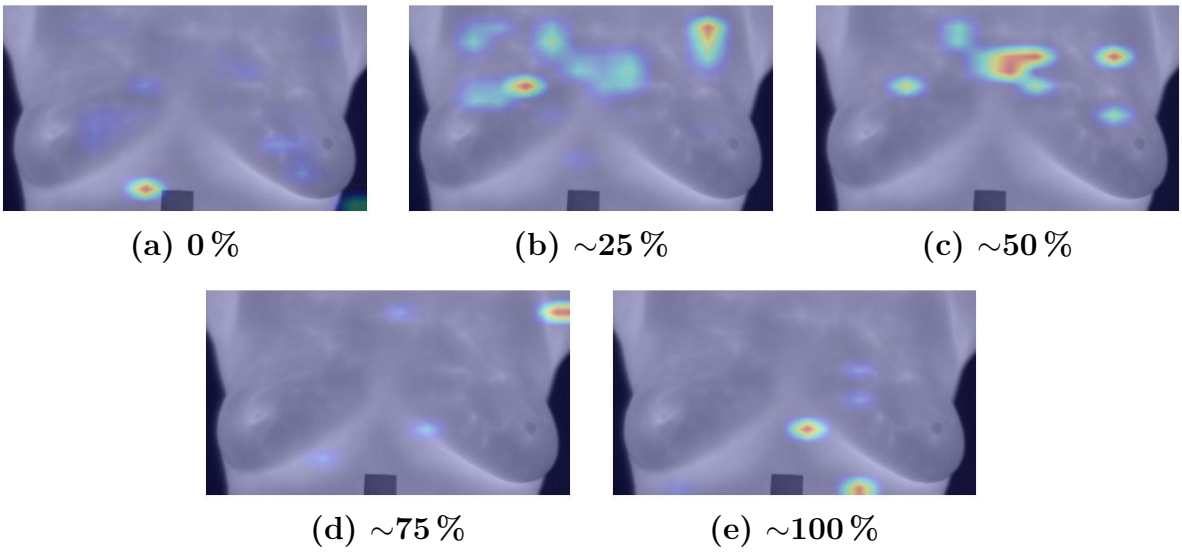
(a) 0 % **(b) ∼25 %** **(c) ∼50 %**

(d) ∼75 % **(e) ∼100 %**

Figura 4.8: Grad-CAM obtenido sobre la muestra enferma 192 para los modelos de predicción entrenados con distinto número de imágenes sintéticas en el conjunto de datos: **(a)** 0 % **(b)** ∼25 % **(c)** ∼50 % **(d)** ∼75 % **(e)** ∼100 %

En cuanto a la paciente 245, en la fig. 4.9 se presentan los mapas de calor. El conjunto base (a) centra su atención en la zona baja del pecho izquierdo, de forma similar a como lo hace el 100 % (e), aunque este también observa la parte central del pecho. El modelo con 25 % de imágenes sintéticas (b) focaliza su atención en el pecho izquierdo y en la parte superior del pecho derecho. El modelo de 50 % (c) centra la atención en la parte central del pecho y parte del derecho. Por último, el 75 % (d) fija su atención en la axila, una zona de interés por su relación con los ganglios ubicados en esa zona.

Esta comparativa permite demostrar cómo se modifica la distribución de las zonas de atención de los modelos dependiendo del porcentaje de imágenes sintéticas utilizadas en el entrenamiento. Asimismo, se proporciona una visión detallada sobre cómo analiza el modelo de atención dura las imágenes del conjunto de datos. Cabe destacar que de los modelos analizados, el que presenta un mayor rendimiento es el del experimento del 25 % (768 imágenes sintéticas), obteniendo una puntuación F1 de 86.82 % y una exhaustividad del 87.43 %.



(a) 0 % **(b) ∼25 %** **(c) ∼50 %**

(d) ∼75 % **(e) ∼100 %**

Figura 4.9: Grad-CAM obtenido sobre la muestra enferma 245 para los modelos de predicción entrenados con distinto número de imágenes sintéticas en el conjunto de datos: **(a)** 0 % **(b)** ∼25 % **(c)** ∼50 % **(d)** ∼75 % **(e)** ∼100 %

4.5. Fallos de convergencia

Como se ha mencionado previamente, los modelos GANs presentan una gran inestabilidad, lo que ocasiona fallos de convergencia si se entrenan un número elevado de veces, como es el caso de los experimentos llevados a cabo, donde en cada uno se entrenan 100 modelos generativos distintos. El fallo de convergencia (explicado en la sección 2.1.2) se produce cuando discriminador y generador no consiguen alcanzar un estado de *Nash Equilibrium*. Debido a esto, se reproducen imágenes negras. Gracias a la afinación de hiperparámetros, se logró reducir el número de fallos de convergencia que se producían. Dado que esta situación es aleatoria y poco frecuente, se decide conservar estas imágenes sintéticas ya que volver a entrenar un modelo y producirlas aumentaría el tiempo de ejecución de los experimentos de manera exponencial. En la fig. 4.10 se observa el número de convergencias presentadas en los experimentos finales, donde se expone que cada ejecución ha tenido 12 fallos de convergencia, excepto la ejecución de 100 % de imágenes sintéticas que presenta únicamente 8. Esto representa aproximadamente el 10 % de fallos de convergencia en las 100 ejecuciones realizadas, lo que se considera una cifra razonable teniendo en cuenta el tamaño del conjunto de datos empleado en este proyecto.

4.6. Discusión

A continuación se analiza el rendimiento de los modelos entrenados con diferentes proporciones de imágenes sintéticas desde distintos puntos de vista: métricas de evaluación, tiempos de ejecución, mapas de atención, étc. Este ha permitido consolidar y presentar de manera

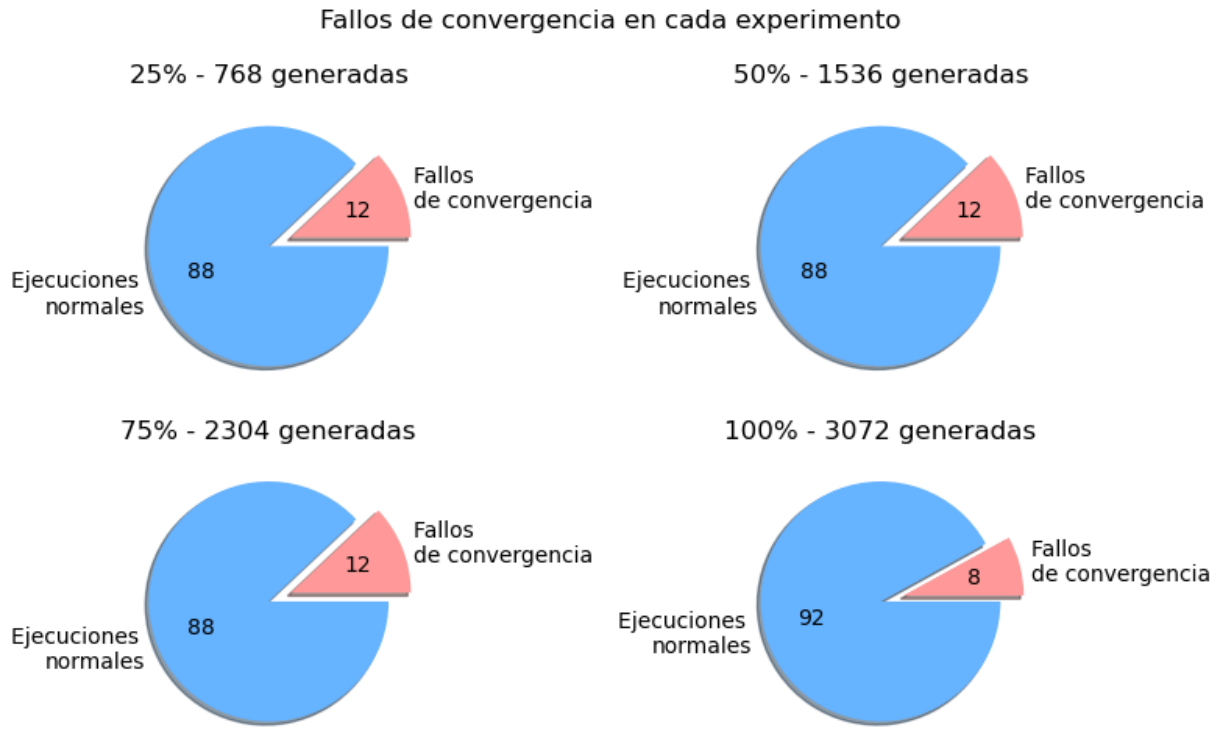


Figura 4.10: Número de ejecuciones de los modelos GANs con fallos de convergencia en cada experimento.

clara los resultados de las ejecuciones finales, cuyo diseño y metodología fueron expuestos en los capítulos anteriores.

Los resultados obtenidos muestran que el aumento de datos mediante GANs aporta beneficios significativos al rendimiento del modelo predictivo de atención dura utilizado en [Aguilar, 2022]. Gracias al proceso optimizado que maximiza el uso de todas las muestras, a la afinación cuidadosa de hiperparámetros y al procedimiento que selecciona las mejores imágenes para el aumento de datos, se mejora el rendimiento y la consistencia de un modelo predictivo incluso cuando el conjunto de datos es muy reducido. A pesar de los resultados, para confirmar que esta técnica mejora el rendimiento del modelo predictivo en cada situación, se debe realizar una enorme cantidad de ejecuciones de forma que se comprueben los resultados con distintas particiones de los datos obteniendo una mayor fiabilidad en las métricas recogidas.

Dentro de los resultados obtenidos, destaca el experimento de 1536 de imágenes generadas (50 %), que demuestra el mejor desempeño en la mayoría de evaluaciones. Este experimento logra el mejor resultado en 3 métricas de evaluación: Exactitud, Exhaustividad y Puntuación F1. Asimismo, poseer el mejor resultado en Exhaustividad supone una ventaja significativa, ya que esta métrica es fundamental en diagnósticos clínicos para reducir el riesgo de falsos negativos. También registra un tiempo de ejecución de 5584 minutos (3.87 días), a diferencia

de los 5883 del 100 %, un AUC de 0.87 que supera al modelo entrenado con el conjunto base y en la matriz de confusión el número de falsos negativos es el menor de todos con 186. A la vista de los resultados obtenidos, se considera que la técnica de aumento de datos mediante imágenes sintéticas no es viable ni recomendable en todos los escenarios pues, aunque logran ciertas mejoras, estas son pequeñas en comparación con el aumento exponencial del tiempo de ejecución.

Capítulo 5

Conclusiones y trabajos futuros

A lo largo de este capítulo se describen los procesos implementados durante el desarrollo de este proyecto, así como los logros conseguidos por el mismo. Asimismo, se analizan los resultados obtenidos y se presenta una evaluación final del estudio. Finalmente, en la siguiente sección se plantean trabajos futuros orientados a mejorar los resultados obtenidos.

5.1. Conclusiones

En este estudio se evalúa la eficacia del aumento de datos mediante GANs aplicado a un reducido conjunto de imágenes térmicas. Se utiliza un modelo predictivo con mecanismos de atención dura, el cuál se entrena con el conjunto base y con conjuntos de datos que integran distinto número de imágenes generadas. Tras evaluar cada entrenamiento, se comparan los datos para comprobar el impacto de las imágenes generadas sobre los resultados. Con el fin de optimizar los resultados, se realizan afinaciones de hiperparámetros a los modelos GAN, se implementa un sistema para seleccionar las mejores imágenes generadas para integrarlas al conjunto de datos y se diseña un flujo de entrenamiento y evaluación que optimiza las imágenes del conjunto, maximizando el uso de las muestras. Para garantizar la robustez de los resultados, se repite el flujo mencionado 10 veces. Los análisis muestran que los conjuntos con imágenes generadas han logrado aumentar ligeramente los resultados en comparación a los del conjunto base.

En relación con los objetivos planteados en el capítulo 1, se confirma que el primero de ellos se ha cumplido mediante la realización de unas pruebas iniciales y una investigación sobre los distintos tipos de GAN, para después seleccionar *StyleGAN* e implementarlo. Respecto al segundo objetivo, se ha desarrollado un sistema de entrenamiento y evaluación para los GANs correspondientes a muestras sanas y enfermas, permitiendo comparar el rendimiento de cada uno. Gracias a la realización de este objetivo, se pudo acometer el siguiente: la afinación de hiperparámetros, que se llevó a cabo seleccionando una serie de parámetros de gran relevancia en la generación de las imágenes y ejecutando durante 78 horas dos afi-

naciones, una para cada modelo. Esto redujo los fallos de convergencia y aumentó la calidad de las imágenes. El siguiente objetivo consiste en definir un sistema para generar imágenes, ejecutar el modelo de predicción y evaluarlo; el cuál se explica en las secciones 3.3 y 3.9. Este se ha llevado a cabo mediante la validación cruzada, usando en cada iteración un procedimiento (fig. 3.9) que optimiza el uso de las imágenes utilizando unas cuantas en los GANs como conjunto de validación y a continuación integrándolas de nuevo al conjunto de entrenamiento. Finalmente, el análisis y evaluación de los resultados, último objetivo del estudio, se presenta en el capítulo 4, donde los datos recopilados demuestran la mejora obtenida gracias a las técnicas implementadas.

En conclusión, este proyecto evidencia buenos resultados bajo el contexto actual, con una metodología robusta a la hora de obtener métricas, lo que reduce los sesgos. Teniendo en cuenta que el conjunto de datos original posee 260 instancias y que los sistemas GANs requieren una gran cantidad de muestras para su correcto funcionamiento, supone un logro significativo para este proyecto la mejora del rendimiento del modelo predictivo. Este proyecto presenta el potencial del aumento de datos mediante GANs, el cuál posee una eficacia incluso en los conjuntos de datos más reducidos. Además, la afinación de hiperparámetros, el procedimiento de entrenamiento y evaluación y la selección de imágenes del aumento de datos han resultado determinantes en la mejora de los resultados del modelo predictivo. En este contexto, mencionar que para demostrar que los resultados mejoran siempre con imágenes sintéticas, se deben realizar un enorme número de ejecuciones para aumentar la fiabilidad.

5.2. Trabajos futuros

A continuación se proponen una serie de líneas de trabajo que podrían ser exploradas en futuros estudios para mejorar los resultados de este trabajo:

- En este proyecto se emplea *StyleGAN* como punto de partida para poder entender y abarcar correctamente su infraestructura, la cuál es muy compleja. Sin embargo, se podrían implementar los mismos procedimientos llevados a cabo con los modelos *StyleGAN2* o *StyleGAN3*, que mejoran algunos aspectos con respecto a su versión base.

- Aplicar la técnica del aprendizaje transferido (*Transfer learning*), que consiste en utilizar modelos ya entrenados, normalmente con millones de imágenes. Esta técnica ha demostrado en muchas ocasiones que usar modelos entrenados bajo imágenes incluso de distinto tipo produce resultados excelentes, por lo que es una buena adición a este trabajo usar un modelo ya entrenado con imágenes en escala de grises o similares.

- Aumentar el conjunto de datos de imágenes reales con nuevas adiciones contactando con los responsables de esta base de datos. Sería interesante contactar desde varios medios para consultar si hay disponibles imágenes nuevas que se puedan añadir al conjunto. Para la realización de este trabajo se contactó con el laboratorio de investigación responsable del conjunto de datos [Lincoln da Silva et al., 2014] pero no se obtuvo respuesta.

- Aumentar el número de iteraciones para la afinación de hiperparámetros y el entrenamiento de los GANs. A pesar de que los tiempos de ejecución de este proyecto han sido enormes, podría ser de ayuda afinar más tiempo aún los modelos GANs y aumentar el tiempo en el que entrenan; vigilando en todo momento que no se produzca un sobreajuste de las imágenes.

Bibliografía

Aguilar, J. C. O. (2022). Trabajo de fin de máster: Deep learning y mecanismos de atención para la detección del cáncer de mama a través de imágenes térmicas.

Alec Radford et al. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks. *ICLR 2016*.

Alia Alshehri et al. (2022). Breast cancer detection in thermography using convolutional neural networks (cnns) with deep attention mechanisms. `https://medium.com/@miraytopal/what-is-mode-collapse-in-gans-d3428a7bd9b8` visto en 22/01/25.

Antreas Antoniou et al. (2018). Data augmentation generative adversarial networks.

Bergmann, D. (2018). ¿qué es el espacio latente? `https://www.ibm.com/es-es/think/topics/latent-space` visto en 01/02/25.

Brownlee, J. (2019). How to implement wasserstein loss for generative adversarial networks. `https://machinelearningmastery.com/how-to-implement-wasserstein-loss-for-generative-adversarial-networks/` visto en 01/02/25.

Brownlee, J. (2020). How to implement a semi-supervised gan (sgan) from scratch in keras. `https://machinelearningmastery.com/semi-supervised-generative-adversarial-network/` visto en 10/05/24.

Brownlee, J. (2021). How to identify and diagnose gan failure modes. `https://machinelearningmastery.com/practical-guide-to-gan-failure-modes/` visto en 28/01/25.

Christian Szegedy et al. (2015). Rethinking the inception architecture for computer vision.

Daniel Jiwoong Im et al. (2016). Generating images with recurrent adversarial networks.

Dmitry Ulyanov et al. (2016). Texture networks: Feed-forward synthesis of textures and stylized images.

Elilah, T. A. (2023). Stylegan implementation from scratch pytorch. `https://www.kaggle.com/code/tauilabdelilah/stylegan-implementation-from-scratch-pytorch` visto en 15/11/24.

Farzan Farnia et al. (2020). Do gans always have nash equilibria? *Proceedings of Machine Learning Research vol 145 (2022) 1–26.*

Hamed Alqahtani et al. (2019). Applications of generative adversarial networks (gans): An updated review. *Archives of Computational Methods in Engineering, 28, 1.*

Holger Schünemann et al. (2020). Breast cancer screening and diagnosis: A synopsis of the european breast guidelines. *Ann Intern Med. 2020 Jan 7;172(1).*

Ian J. Goodfellow et al. (2014). Generative adversarial networks.

Leon A. Gatys et al. (2016). Image style transfer using convolutional neural networks. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR).*

Lincoln da Silva et al. (2014). A new database for breast research with infrared image. *Journal of Medical Imaging and Health Informatics*, 4:92–100.

Manasi B. Rakhunde et al. (2022). Thermography as a breast cancer screening technique: A review article. *Cureus. 2022 Nov 8;14(11).*

Martin Arjovsky et al. (2017). Wasserstein gan.

Martin Heusel et al. (2017). Gans trained by a two time-scale update rule converge to a local nash equilibrium.

Mehdi Mirza et al. (2018). Conditional generative adversarial nets.

Mesut Toğaçar et al (2020). Breast-net: A novel convolutional neural network model through histopathological images for the diagnosis of breast cancer. *Physica A: Statistical Mechanics and its Applications, Volume 545, 1 May 2020, 123592.*

Mikołaj Bińkowski et al. (2018). Demystifying mmd gans. *ICLR 2018.*

Olaf Ronneberger et al. (2015). U-net: Convolutional networks for biomedical image segmentation.

OMS (2024). Cáncer de mama. `https://www.who.int/es/news-room/fact-sheets/detail/breast-cancer` visto en 07/01/25.

Ramprasaath R. Selvaraju et al. (2019). Grad-cam: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision (IJCV).*

Sam Bond-Taylor et al. (2021). Deep generative modelling: A comparative review of vaes, gans, normalizing flows, energy-based and autoregressive models. *IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE, VOL. 44, NOVEMBER 2022*.

Saman Motamed et al. (2021). Data augmentation using generative adversarial networks (gans) for gan-based detection of pneumonia and covid-19 in chest x-ray images. *Informatics in Medicine Unlocked*, 27:100779.

Tero Karras et al. (2018). A style-based generator architecture for generative adversarial networks. *CVPR 2019*.

Tero Karras et al. (2020). Training generative adversarial networks with limited data.

Tero Karras et al. (2021). Alias-free generative adversarial networks.

Tero Karrase et al. (2020). Analyzing and improving the image quality of stylegan.

Tian Qi Chen et al. (2016). Fast patch-based style transfer of arbitrary style.

TOPAL, M. (2023). What is mode collapse in gans? `https://medium.com/@miraytopal/what-is-mode-collapse-in-gans-d3428a7bd9b8` visto en 28/01/25.

Wikipedia (2023). Validación cruzada. `https://es.wikipedia.org/wiki/Validaci%C3%B3n_cruzada` visto en 16/02/25.

Wikipedia (2025a). Fréchet inception distance. `https://en.wikipedia.org/wiki/Fr%C3%A9chet_inception_distance` visto en 25/02/25.

Wikipedia (2025b). Hyperparameter optimization. `https://en.wikipedia.org/wiki/Hyperparameter_optimization` visto en 16/02/25.

Xun Huang et al. (2017). Arbitrary style transfer in real-time with adaptive instance normalization. *CCV 2017*.